



Universidad Internacional de La Rioja

Escuela Superior de Ingeniería y Tecnología

Máster Universitario en Inteligencia Artificial

Redes Generativas de Aprendizaje Profundo para la mejora de la señal astronómica

Trabajo fin de estudio
presentado por:

Tipo de trabajo

Director

Fecha

Carla Sequero
J. Javier Cacho

Desarrollo de Software

Dr. Guillermo Torralba Elipe

2026-04-14

Resumen

El uso de métodos de Machine Learning en astronomía se ha centrado principalmente en la clasificación y agrupamiento (Djorgovski et al., 2022). En los últimos años, las Redes Generativas Antagónicas también se han utilizado para generar datos astronómicos sintéticos -véase por ejemplo «García-Jara et al. (2022)». Sin embargo, los métodos de aprendizaje profundo siguen siendo un campo novedoso que merece ser explorado (Ting, 2025). En este trabajo proponemos un enfoque innovador para mejorar la calidad de las señales astronómicas en las longitudes de onda del Espectro Azul y Rojo (BS/RS). Al entrenar un modelo a partir de la gran cantidad de datos de baja resolución recopilados por la misión Gaia y cruzarlas con las observaciones terrestres de alta resolución, se esperan encontrar patrones ocultos que puedan aplicarse a los datos de baja resolución para aproximar los de alta resolución. Para evaluar este método se usan varios subconjuntos del conjunto de datos original y se comparan con las observaciones reales de fuentes de alta resolución terrestres.

Abstract

The use of Machine Learning methods in astronomy has been mainly focused on classification and clustering (Djorgovski et al., 2022). In recent years, Generative Adversarial Networks have been used as well to generate synthetic astronomical data -see for example García-Jara et al. (2022). However, deep learning methods are still a novel field worthy to be explored (Ting, 2025). In this paper we propose an innovative approach to improve the quality of astronomical signals in the Blue and Red Spectrum wavelengths (BS/RS). By training a model from the huge amount of low resolution data collected by the Gaia mission and the cross matched best high resolution ground based observations we expect to find hidden patterns that can be applied to allow the usage of these low resolution spectrum as proxy for high resolution ones. We evaluate our method on several benchmark subsets of the original dataset by comparing it with the real observations from high resolution sources.

Índice

1. Introducción	1
1.1. Motivación	2
1.2. Planteamiento del trabajo	3
1.3. Estructura del trabajo	3
2. Contexto y estado del arte	3
2.1. Contexto del problema	3
2.2. Estado del arte	6
2.2.1. Modelos generativos en Astronomía	6
2.3. Aprendizaje profundo en Astrofísica	7
2.4. Conclusiones	8
3. Objetivos concretos y metodología de trabajo	9
3.1. Objetivo general	9
3.2. Objetivos específicos	9
3.3. Metodología de trabajo	9
4. Identificación de requisitos	10
5. Descripción de la herramienta software desarrollada	11
6. Evaluación	12
Referencias bibliográficas	13

1. Introducción

En Diciembre de 2013 comenzó la misión GAIA (*Global Astrometric Interferometer for Astrophysics*) de la Agencia Espacial Europea. El satélite que mencionaremos de ahora en adelante como Gaia, fue puesto en el espacio con el objetivo de crear un mapa que permita conocer mas detalles del Sistema Solar y la Vía Láctea. Esta misión es considerada la sucesora de Hipparcos dentro de ESA, siendo este el primer satélite dedicado a la astrometría. Dicha misión fue puesta en marcha en el 1989 y finalizó en el 1993. Los datos que Gaia aporta son 200 veces mas precisos que los obtenidos por dicho satélite, pero aún así, de menor calidad que los obtenidos por otras misiones(European Space Agency (ESA), 2025).

La propia agencia ESA describe en el reporte publicado en 2013 donde explicaban detalles de la misión de Gaia (Clark, 2013) que antes de estudiar un objeto celeste, es necesario poder ubicarlo en el plano, de lo contrario solo tendrían un conjunto de datos sin sentido pertenecientes a un mismo conjunto pero sin un orden o punto de referencia, en sus propias palabras, describen lo siguiente:

«Antes de que los astrónomos puedan estudiar un objeto celeste, deben saber dónde encontrarlo. Sin este conocimiento, los astrónomos vagarían en vano en lo que Galileo alguna vez llamó un oscuro laberinto»

Por este motivo, la misión principal de Gaia se puede considerar muy útil para continuar desarrollando estudios y conocimientos acerca del universo.

Más allá de este objetivo, Gaia ha podido aportar descubrimientos de objetos celestes que anteriormente no conocíamos (Clark, 2013). Esta misión ha proporcionado uno de los catálogos mas extensos y precisos hasta la fecha (Agencia Espacial Europea (ESA), 2025), no solo aportando datos astrométricos, sino que también fotométricos y espectrofotométricos. Todos estos datos se basan en mediciones de espectros de baja resolución como lo son los BP/RP.

Otras misiones como ahora la iniciada en XXXX por XXXX con el survey (proyecto astronómico) *Sloan Digital Sky Survey (SDSS)*, son capaces de proporcionar mediciones con mayor resolución que Gaia, pero con un alcance menor. De este hecho parte la idea del trabajo que se desarrolla a continuación.

Si pudiesemos definir una similitud entre los espectros obtenidos por Gaia y SDSS, conseguiríamos combinar lo mejor de ambos proyectos, el rango espacial que Gaia ha sido capaz de conseguir junto a el detalle que SDSS conlleva. En este contexto, gracias a los avances constantes de la inteligencia artificial, en este trabajo proponemos explorar técnicas que nos permitan llevar a cabo este objetivo; convertir espectros de Gaia en su equivalente SDSS y viceversa.

1.1. Motivación

A lo largo de 2026 se publicarán los últimos datos recolectados por Gaia en un último DR4 y catálogo final DR5. Se calcula que a lo largo de la misión, unos 2 billones de estrellas y otros objetos celestes fueron captados por el satélite. (Agencia Espacial Europea (ESA), 2025) También ha permitido disponer de una imagen reconstruida sobre cómo un observador vería nuestra galaxia desde el exterior de esta, pudiendo crear así un mapa tridimensional de alrededor de 1,3 millones de cúasares. Cabe destacar la gran diferencia respecto a su antecesor Hipparcos, dado que dicha misión, en su release final publicó un catálogo de 2,5 millones de estrellas comparado con los aproximadamente 2 billones que Gaia datará a lo largo de toda su misión(Clark, 2013).

Estas son solo algunas de las hazañas que se han conseguido a partir de los datos qe Gaia ha recogido durante su misión. Dichos datos partían de dos espectros de baja resolución (Clark, 2013). La motivación de este trabajo parte de la pregunta «¿Que hubiese sucedido si Gaia hubiese iniciado su viaje con una mayor resolución de los espectros captados?».

Otros satélites como SDSS (ya mencionado anteriormente), presentan una resolución mucho mayor a Gaia (), pero se han visto limitados por su ubicación, dado que SDSS depende de dos telescopios situados en el Observatorio Apache Point de Nuevo México y en el de Las Campanas de Carnegie en Chile (Sloan Digital Sky Survey Collaboration, 2020).

Desde este punto de vista, el potencial que un satélite como Gaia hubiese desarrollado teniendo las características de Sloan, parece indescrignable. Por este motivo, en este trabajo queremos centrarnos en encontrar una relación o equivalencia entre los espectros de Gaia y los de Sloan. De esta forma, podríamos comparar el mismo cuerpo celeste observado desde los dos proyectos, y así tratar de conseguir una implementación de filtros de mejora de señal en Gaia, basados en los datos obtenidos de su comparación o estudio frente a Sloan.

1.2. Planteamiento del trabajo

1.3. Estructura del trabajo

2. Contexto y estado del arte

2.1. Contexto del problema

Antes de enfocarnos en el desarrollo central de este trabajo, debemos contextualizar con que datos trabajaremos y cuales son sus características. En primer lugar nos centraremos en el satélite Gaia y el tipo de datos que aporta junto a como los obtiene. Gaia es el satélite principal de esta investigación, es el que aporta la motivación principal del trabajo, tiene muchos datos, pero con mucho ruido y por lo tanto mucho margen de error.

Los datos de Gaia serán comparados con los del survey SDSS o Sloan, como lo llamaremos en este estudio. Deberemos encontrar las relaciones entre los datos que aportan ambos satélites para ser capaces de transformar espectros de Sloan en Gaia o viceversa.

Comenzaremos con una descripción detallada acerca de como los datos de Gaia son recogidos y tratados.

El satélite Gaia aporta datos como por ejemplo el brillo, la temperatura, la composición y la masa. Para conseguirlo, consta de 3 instrumentos para detectar la luz que recogen los telescopios del satélite. El primero, conocido como astrómetro, mide las posiciones estelares en el cielo, el espectrómetro medirá las velocidades radiales (RVS) y, por último, el instrumento fotométrico aportará dos espectros de baja resolución de dos bandas ópticas, la azul y la roja. Con dichos espectros se podrá determinar los datos anteriormente mencionados. Gaia Collaboration & European Space Agency (2023)

El satélite en cuestión se encuentra en una posición espacial conocida como L2, ubicada a 1,5 millones de kilómetros de la Tierra y donde las fuerzas gravitacionales del Sol, la Tierra y la Luna están en equilibrio. Por otro lado, el satélite, el Sol y la Tierra siempre van a permanecer alineados, impidiendo así que ninguno de los cuerpos celestes mencionados se interponga en el campo de visión de Gaia. European Space Agency (2013)

Redes Generativas de Aprendizaje Profundo para la mejora de la señal astronómica

La información viaja a la Tierra a una velocidad de 5Mbit/s, y es captado por las antenas de Cebreros (España) y Nueva Norcia (Australia). La colección de datos de Gaia comenzó el 25 de julio de 2014 y finalizó el 15 de enero de 2025, desde el 27 de Marzo de 2025 Gaia se posicionó en su órbita de retiro alrededor del Sol (European Space Agency (ESA), 2025).

Para entender como Gaia recoge todos los datos que disponemos a día de hoy, es imprescindible entender sus *Scanning Laws* o mejor dicho, las reglas que determinan como se gira y mueve para escanear el cielo. Por un lado, el satélite rota sobre si mismo cada 6 horas, al mismo tiempo el eje de rotación cambia con un periodo de 63 días pero siempre manteniéndose a 45 grados respecto al Sol, finalmente como anteriormente hemos comentado, este satélite orbita alrededor del Sol junto a la Tierra. De estos movimientos, se estima que durante los años de misión se han obtenido unas 70 mediciones astrometricas y fotométricas junto con aproximadamente 40 mediciones espectroscópicas usables por cada estrella. Gaia Collaboration & European Space Agency (2023)

A continuación, nos centraremos en entender como los datos que serán usados a lo largo del trabajo han sido obtenidos. Es decir, como se ha transformado la data original que Gaia ha recogido en su misión en datos comprensibles. Cabe destacar que el organismo encargado de este procesado se denomina DPAC (*Data Processing and Analysis Consortium*). Para ser específicos, las unidades de coordinación que trabajan especialmente en los datos que son de interés para este estudio son el 3, 5, 6 y 8.

En primer lugar, la CU3 (*Coordination Unit*) se encarga del procesamiento astométrico de Gaia, obteniendo por lo tanto datos acerca de los movimientos y posiciones de las estrellas. Estos datos los usaremos para definir que cuerpos celestes consideramos en el estudio, dado que debemos tener en cuenta su posición para estar seguros de que se comparan los mismos cuerpos celestes. Consideraremos una desviación de 0.02 grados .

La CU5 procesa los datos fotométricos, es decir de los ya anteriormente mencionados espectros BP y RP (*Blue Photometer* y *Red Photometer*). En el último *release* de datos (número 3), la media de la data recogida los últimos 34 meses fue usada, ya que como hemos comentado anteriormente en el apartado 1, el satélite toma datos del mismo cuerpo varias veces. Debida a la baja definición de los espectros BR/PR, se usan los *spectral-shape coefficients* (SCP), una derivación de los espectros

Redes Generativas de Aprendizaje Profundo para la mejora de la señal astronómica

BR/PR que permiten distribuir el flujo en bandas o rangos espectrales categorizados por los nanómetros.

El preprocesado de estos datos se puede dividir en varios pasos o puntos. Como el release más actualizado es el DR3, nos centraremos en las técnicas aplicadas en esta base. El proceso comienza con una reducción del ruido de fondo, como por ejemplo el causado por la luz solar o de otras estrellas. La complicación de este paso parte de que el ruido introducido no es completamente aleatorio, también dependerá de la posición actual del satélite respecto al Sol, añadiendo por lo tanto periodicidad a las fluctuaciones observadas. En este caso concreto, el ruido espacial puede llegar a ubicarse cerca de los 27 electrones/píxel/segundo, mientras que la media habitual, en condiciones estáticas del espacio, es de 0.2 electrones/píxel/segundo.

GAIA consta de diferentes *CCDs (Charge-Coupled Devices)*, es decir, sensores que captan la luz y la convierten en una señal que se pueda digitalizar. Los espejos o lentes del satélite se encuentran en ángulos diferentes respecto a los detectores de señales CCD, y al mismo tiempo, como GAIA se encuentra en constante movimiento, obtenemos datos con diferentes posiciones *AL (Along Scan)*, esto resulta en la obtención de datos del mismo cuerpo celeste pero con diferentes longitudes de onda y pequeñas desviaciones entre tomas. Por eso es necesario corregir los datos obtenidos a partir de dos procesos denominados Correcciones diferenciales geométricas y de dispersión. Por último, se lleva a cabo una Calibración, interna y externa, con la que se transforman a un sistema fotométrico común todos los datos captados con diferentes escenarios y, finalmente, se adecuan los datos a un flujo físico universal que pueda ser comparado con la información obtenida por otros satélites.

El procesamiento espectroscópico de los datos de Gaia se lleva a cabo en la CU6 a partir de la información recogida por el *RVS (Radial Velocity Spectrometer)*. Estos espectros de rango situado entre 845 a 872 nanómetros servirán para determinar la velocidad radial de las estrellas. Para aumentar la calidad y poder manejar la información, igual que en el caso anterior, se llevarán a cabo diferentes procesos de limpieza y corrección de dichos espectros. También se calibrarán y combinarán los diferentes valores captados por las diversas mediciones del mismo cuerpo celeste que Gaia recogió durante su misión.

Finalmente, en la CU8, a partir de todos los datos procesados hasta el momento (astrométricos, fotométricos y espectroscópicos), se obtendrán parámetros astrofísicos como la temperatura o la

fuerza gravitatoria en la superficie del cuerpo. De ahí la importancia de conseguir datos no sesgados y libres de ruido como resultado de las primeras unidades de procesamiento de la información. Las características con las que se definan los elementos observados van a depender directamente de como la data es tratada y de la calidad que esta presente.

2.2. Estado del arte

En los últimos años la astronomía se ha beneficiado de las técnicas de aprendizaje automático, principalmente en tareas tradicionales como clasificación y agrupamiento. Por ejemplo, Djorgovski et al. (2022) señalan que «una amplia variedad de métodos de clasificación y agrupamiento se ha aplicado a estas tareas, y sigue siendo un área de investigación muy activa». En efecto, muchos esfuerzos han estado enfocados en reconocer tipos de estrellas o galaxias, identificar eventos transitorios, y separar estrellas de galaxias, aprovechando catálogos masivos con miles de características. Estos enfoques basados en aprendizaje automático clásico han permitido lidiar con el flujo de datos de observaciones astronómicas mediante el uso de la clasificación supervisada o el agrupamiento no supervisado.

2.2.1. Modelos generativos en Astronomía

Paralelamente, ha crecido el interés en generar datos astronómicos sintéticos mediante modelos generativos. En particular, las Redes Generativas Antagónicas (GANs) se han aplicado con éxito en algunos contextos. Por ejemplo, García-Jara et al. (2022) propusieron un método de data augmentation basado en GANs para generar curvas de luz sintéticas de estrellas variables y mostraron cómo su modelo GAN logra producir variaciones realistas de luminosidad, mejorando significativamente la precisión de clasificación cuando se entrena con estos datos sintéticos adicionales. Esto ejemplifica cómo las GANs pueden crear nuevos ejemplos de baja complejidad (en este caso series temporales) para compensar la escasez de datos etiquetados.

Asimismo, dada la enorme base de datos espectrales de baja resolución de la misión Gaia (más de 220 millones de espectros BP/RP en Gaia DR3), se han desarrollado modelos generativos específicos para estos datos. Laroche & Speagle (2025) introdujeron un **autoencoder variacional generativo no supervisado** que aprende directamente de los espectros Gaia sin necesidad de etiquetas estelares (Laroche & Speagle, 2025). Su modelo reproduce los espectros BP/RP y detecta patrones en áreas donde el aprendizaje supervisado falla debido a la falta de referencias. De hecho, antes de este

trabajo la única aproximación generativa para los espectros Gaia era supervisada basada en un conjunto reducido de estrellas cruzadas con observaciones terrestres (LAMOST) (Zhang et al., 2023). Estos desarrollos recientes demuestran que los modelos generativos pueden explorar el conjunto masivo de datos Gaia para *aproximar* datos de mayor resolución.

2.3. Aprendizaje profundo en Astrofísica

A pesar de estos avances, el uso de **redes neuronales profundas** en astronomía sigue siendo relativamente reciente y sujeto a debate. Ting (2025) destaca que, aunque estas técnicas ofrecen *perspectivas diversas* y capacidades de modelar relaciones complejas, todavía enfrentan retos importantes. Según Ting, la astronomía ha entrado en una era de datos sin precedentes, lo que ha impulsado a muchos investigadores a adoptar métodos de aprendizaje profundo para procesar observaciones modernas. Sin embargo, las reacciones varían: algunos científicos ven estas redes profundas como herramientas transformadoras, mientras que otros se muestran escépticos sobre sus verdaderas ventajas. En este contexto, se advierte que aunque las arquitecturas neuronales pueden incorporar sesgos físicos (simetrías, leyes de conservación) en su diseño para generalizar mejor, sigue siendo necesario evaluar cuidadosamente sus resultados. En resumen, el aprendizaje profundo en astrofísica está emergiendo como una vía prometedora que aún se encuentra en una fase exploratoria y que requiere una validación rigurosa antes de tener una aceptación generalizada en este dominio.

El ejemplo más cercano al enfoque propuesto en este trabajo lo encontramos en un trabajo muy reciente de Haghjoo et al. (2026). En dicha propuesta, se usaron datos del *James Web Space Telescope (JWST)* emparejando las observaciones de los instrumentos de baja resolución con los de alta resolución mediante un modelo generativo. Dicho modelo aprendió a realzar características espectrales débiles (como líneas de emisión solapadas) que originalmente estaban fuera del alcance de la baja resolución. Aunque este ejemplo proviene de observaciones en el infrarrojo cercano, ilustra la factibilidad de entrenar redes con datos emparejados (baja vs. alta resolución) para recuperar detalles perdidos. De manera similar, el presente trabajo propone utilizar pares de espectros Gaia (baja resolución) y observaciones terrestres de alta resolución, buscando descubrir patrones ocultos que permitan aproximar los espectros Gaia a la alta resolución. Como se ha comentado, este tipo de enfoque es relativamente novedoso y es muy interesante explorar su potencial.

2.4. Conclusiones

3. Objetivos concretos y metodología de trabajo

3.1. Objetivo general

3.2. Objetivos específicos

3.3. Metodología de trabajo

4. Identificación de requisitos

5. Descripción de la herramienta software desarrollada

6. Evaluación

Referencias bibliográficas

- Agencia Espacial Europea (ESA). (2025, enero 15). *Última luz estelar para la pionera Gaia*. https://www.esa.int/Space_in_Member_States/Spain/Ultima_luz_estelar_para_la_pionera_Gaia
- Bick, A., Blandin, A., & Deming, D. J. (2026). The rapid adoption of generative AI. *Management Science*.
- Clark, S. (2013). *Gaia: El censo galáctico de la ESA. BR-296*. https://esamultimedia.esa.int/docs/science/BR-296-Spanish_Gaia_05_WEB.pdf
- Djorgovski, S. G., Mahabal, A., Graham, M. J., Polsterer, K., & Krone-Martins, A. (2022). Applications of AI in Astronomy. *arXiv preprint arXiv:2212.01493*.
- European Space Agency. (2013,). *Datos clave de la misión Gaia: Un proyecto para catalogar mil millones de estrellas*. https://www.esa.int/Space_in_Member_States/Spain/Datos_clave_de_la_mision_Gaia_-_Un_proyecto_para_catalogar_mil_millones_de_estrellas_-
- European Space Agency (ESA). (2025,). *Gaia overview*. https://www.esa.int/Science_Exploration/Space_Science/Gaia_overview
- Gaia Collaboration, & European Space Agency. (2023). *Gaia Data Release 3 Documentation*. <https://gea.esac.esa.int/archive/documentation/GDR3/>
- García-Jara, G., Protopapas, P., & Estévez, P. A. (2022). Improving astronomical time-series classification via data augmentation with generative adversarial networks. *The Astrophysical Journal*, 935(1), 23.
- Haghjoo, A., Hemmati, S., Mobasher, B., Chartab, N., Vega, A. de la, Eifler, T., Everetts, E., Nayyeri, H., & Sattari, Z. (2026). Learning to See Sharper: A Physics-Informed Artificial Intelligence Framework for Super-Resolving Galaxy Spectra. *arXiv preprint arXiv:2603.18357*.
- Laroche, A., & Speagle, J. S. (2025). Closing the stellar labels gap: Stellar label independent evidence for $[\alpha/M]$ information in Gaia BP/RP spectra. *The Astrophysical Journal*, 979(1), 5.

Redes Generativas de Aprendizaje Profundo para la mejora de la señal astronómica

Sloan Digital Sky Survey Collaboration. (2020, noviembre 2). *La próxima generación de estudios astronómicos realiza sus primeras observaciones para una nueva comprensión del cosmos*. <https://www.sdss.org/la-proxima-generacion-de-estudios-astronomicos-realiza-sus-primeras-observaciones-para-una-nueva-comprension-del-cosmos/>

Ting, Y.-S. (2025). Deep learning in astrophysics. *arXiv preprint arXiv:2510.10713*.

Zhang, X., Green, G. M., & Rix, H.-W. (2023). Parameters of 220 million stars from Gaia BP/RP spectra. *Monthly Notices of the Royal Astronomical Society*, 524(2), 1855-1884.