



Universidad Internacional de La Rioja

Escuela Superior de Ingeniería y Tecnología

Máster Universitario en Inteligencia Artificial

**Redes Generativas de Aprendizaje
Profundo para la mejora de la señal
astronómica**

Trabajo fin de estudio presentado por:	Carla Sequero, J. Javier Cacho
Tipo de trabajo:	Proyecto Piloto
Director:	Dr. Guillermo Torralba Elipe
Fecha:	2026-02-05

Resumen

En este trabajo se propone un enfoque basado en aprendizaje profundo para mejorar la calidad de los espectros de baja resolución captados por los fotómetros azul (BP) y rojo (RP) del satélite Gaia, aproximándolos a espectros de mayor resolución equivalentes a los del *Sloan Digital Sky Survey* (SDSS). Para ello se ha construido un conjunto de datos propio con más de 55 000 pares de espectros emparejados de Gaia y SDSS, obtenido al cruzar la tercera liberación de datos de Gaia (DR3) con la decimotercera de SDSS (DR13) mediante la tabla oficial de mejores vecinos, y depurado con criterios de calidad basados en la relación señal-ruido y en la coherencia entre ambas fuentes. Sobre este conjunto se han entrenado y comparado tres arquitecturas de red neuronal: una red densa, una red convolucional unidimensional (CNN) y una red recurrente (RNN).

Los resultados muestran que la red densa, combinada con una normalización por la mediana de cada espectro, proporciona las mejores aproximaciones: las predicciones reproducen la morfología general del espectro de SDSS, incluidos sus picos más acentuados, y la similitud de las métricas obtenidas en entrenamiento, validación y test descarta el sobreajuste. Además de la comparación directa con las observaciones reales, los espectros generados se han validado estimando con la librería *iSpec* parámetros astrofísicos como la temperatura efectiva, la gravedad superficial y la metalicidad, con errores relativos medianos inferiores al 1% en temperatura y gravedad respecto a los derivados de los espectros reales de SDSS. Estos resultados demuestran la viabilidad de emplear redes neuronales para trasladar el detalle de las observaciones terrestres de alta resolución al extenso catálogo de Gaia.

Palabras clave: inteligencia artificial generativa, aprendizaje automático, espectro azul, espectro rojo, Gaia, astronomía

Abstract

This work proposes a deep learning-based approach to improve the quality of the low-resolution spectra captured by the blue (BP) and red (RP) photometers of the Gaia satellite, approximating them to higher-resolution spectra equivalent to those of the *Sloan Digital Sky Survey* (SDSS). To this end, a dedicated dataset of more than 55,000 matched pairs of Gaia and SDSS spectra has been built by cross-matching the third Gaia data release (DR3) with the thirteenth SDSS data release (DR13) through the official best-neighbour table, and refined with quality criteria based on the signal-to-noise ratio and on the consistency between both sources. Three neural network architectures have been trained and compared on this dataset: a dense network, a one-dimensional convolutional network (CNN), and a recurrent network (RNN).

The results show that the dense network, combined with a per-spectrum median normalization, provides the best approximations: the predictions reproduce the overall morphology of the SDSS spectrum, including its most prominent peaks, and the similarity of the metrics obtained on the training, validation, and test sets rules out overfitting. In addition to the direct comparison against real observations, the generated spectra have been validated by estimating astrophysical parameters with the iSpec library, such as the effective temperature, the surface gravity, and the metallicity, with median relative errors below 1% in temperature and gravity with respect to those derived from the real SDSS spectra. These results demonstrate the feasibility of using neural networks to transfer the detail of high-resolution ground-based observations to the vast Gaia catalogue.

Keywords: generative ai, machine learning, blue spectrum, red spectrum, gaia, astronomy

Índice de contenidos

1. Introducción	1
1.1. Motivación	2
1.2. Planteamiento del trabajo	2
1.3. Estructura del trabajo	3
2. Contexto y estado del arte	5
2.1. Contexto del problema	5
2.2. Estado del arte	10
2.3. Conclusiones	14
3. Objetivos concretos y metodología de trabajo	16
3.1. Objetivo general	16
3.2. Objetivos específicos	16
3.3. Metodología de trabajo	18
4. Descripción del experimento	20
4.1. Definición de los requisitos	20
4.2. Preparación del conjunto de datos	24
4.3. Análisis de la Signal-to-Noise Ratio (SNR; relación señal-ruido) de los datos obtenidos	28
4.4. Entrenamiento del modelo	31
5. Descripción de los resultados	39
5.1. Resultados obtenidos con el modelo base	39
5.2. Resultados obtenidos con los modelos convolucionales	49
5.3. Resultados obtenidos con el modelo recurrente	56
6. Discusión	63
7. Conclusiones y trabajo futuro	65
7.1. Conclusiones	65
7.2. Trabajo futuro	66

Referencias bibliográficas	68
----------------------------------	----

Índice de figuras

Figura 2.1	Ejemplo de espectro estelar observado por SDSS	6
Figura 2.2	Ejemplo aleatorio del espectro captado de un mismo cuerpo por Gaia y SDSS ...	9
Figura 2.3	Ejemplo del procedimiento de mejora de datos aplicado a un par de espectros JADES de baja y alta resolución: sobre el espectro original (negro) se generan veinte realizaciones sintéticas (líneas de color) mediante desplazamientos aleatorios del corrimiento al rojo y perturbaciones de flujo.	13
Figura 4.1	Ejemplo de espectros donde el espectro de SDSS es constante 0.	21
Figura 4.2	Ejemplo de espectros donde la escala de Gaia y SDSS es diferente.	22
Figura 4.3	Diagrama HR de las observaciones de Gaia contenidas en la base de datos	27
Figura 4.4	Distribución de la SNR de los espectros de Gaia y SDSS	28
Figura 4.5	Distribución del error relativo según la longitud de onda de los espectros de Gaia	29
Figura 4.6	Distribución del error relativo según la longitud de onda de los espectros de SDSS	30
Figura 4.7	Ejemplos de los espectros observados por Gaia y SDSS con bandas de error	31
Figura 5.1	Gráfica de la evolución del MAE en el modelo de redes neuronales densas con normalización global.	40
Figura 5.2	Ejemplos de espectros generados por el modelo de redes neuronales densas con normalización basada en la mediana del conjunto de entrenamiento.	41
Figura 5.3	Gráficas de evolución de las métricas de entrenamiento en la red densa.	42
Figura 5.4	Ejemplos de espectros generados por el modelo de redes neuronales densas con normalización basada en la mediana de cada espectro.	43
Figura 5.5	Ejemplos de espectros generados por el modelo de redes neuronales densas con normalización basada en el máximo de cada espectro.	44
Figura 5.6	Gráficos de barras de errores absolutos respecto iSpec entre los espectros reales de SDSS y los predichos.	47
Figura 5.7	Ejemplos de espectros generados por el modelo de redes neuronales densas con la variable SNR como entrada.	48
Figura 5.8	Gráficas de las métricas de evolución de entranamiento en modelo convolucional 1D	50

Figura 5.9	Ejemplos de espectros generados por el modelo convolucional 1D.	52
Figura 5.10	Gráficas de la evolución de las métricas de entrenamiento del modelo convolucional U-Net	53
Figura 5.11	Ejemplos de espectros generados por el modelo convolucional U-Net.	55
Figura 5.12	Ejemplo 1 del espectro generado por el modelo de redes neuronales recurrentes con una capa de GRU.	57
Figura 5.13	Ejemplo 2 del espectro generado por el modelo de redes neuronales recurrentes con una capa de GRU.	57
Figura 5.14	Ejemplos de espectros generado por el modelo de redes neuronales recurrentes con una capa bidireccional.	59
Figura 5.15	Ejemplos de espectros generados por el modelo de redes neuronales recurrentes con una función de Atención.	61

Índice de tablas

Tabla 5.1	Resultados obtenidos con distintas estrategias de normalización.	45
Tabla 5.2	Resultados obtenidos incluyendo la SNR de la muestra de Gaia como entrada del modelo.	49
Tabla 5.3	Resultados obtenidos sobre el conjunto de test con el modelo convolucional 1D.	50
Tabla 5.4	Resultados obtenidos sobre el conjunto de test con el modelo convolucional U-Net.	54
Tabla 5.5	Resultados obtenidos con el primer modelo basado en GRU para los diferentes conjuntos de datos.	56
Tabla 5.6	Resultados obtenidos con el modelo basado en RNN bidireccionales para los diferentes conjuntos de datos.	58
Tabla 5.7	Resultados obtenidos con el modelo basado en RNN bidireccionales y la función de Atención para los diferentes conjuntos de datos.	60
Tabla 5.8	Resultados obtenidos con iSpec en los modelos destacados basados en RNNs. ...	62
Tabla 6.1	Chi-cuadrado normalizado aplicado sobre los conjuntos de test predichos por los diversos modelos estudiados.	64

Índice de acrónimos

- ADQL:** *Astronomical Data Query Language*
- BP/RP:** *Blue Photometer / Red Photometer*
- DR:** *Data Release* (liberación de datos)
- ELBO:** *Evidence Lower Bound* (cota inferior de la evidencia)
- ESA:** *European Space Agency* (Agencia Espacial Europea)
- FITS:** *Flexible Image Transport System*
- GAN:** *Generative Adversarial Network* (red generativa antagónica)
- GRU:** *Gated Recurrent Unit*
- HR:** *Hertzsprung-Russell*
- IA:** Inteligencia Artificial
- JADES:** *JWST Advanced Deep Extragalactic Survey*
- JWST:** *James Webb Space Telescope*
- MAE:** *Mean Absolute Error*
- MaNGA:** *Mapping Nearby Galaxies at Apache Point Observatory*
- MSE:** *Mean Squared Error*
- RVS:** *Radial Velocity Spectrometer*
- SDSS:** *Sloan Digital Sky Survey*
- SNR:** *Signal-to-Noise Ratio* (relación señal-ruido)
- XP:** Espectros conjuntos BP/RP de Gaia

Organización del trabajo en grupo

Este trabajo ha sido desarrollado de manera conjunta por los dos autores. Para coordinar el desarrollo se han mantenido reuniones periódicas de seguimiento, junto con las revisiones con el director del trabajo, y se ha empleado un repositorio de control de versiones compartido tanto para el código como para la memoria, donde los avances de cada autor se han integrado mediante revisiones cruzadas.

En cuanto al reparto concreto de las tareas, el desarrollo del código usado se ha dividido principalmente en dos bloques. Por un lado, Javier se encargó de la creación del proceso de extracción de los datos para el entrenamiento del modelo, incluyendo la extracción de datos de Gaia y Sloan Digital Sky Survey (SDSS) y su descarga. En cambio, Carla se centró en el preprocesado de dicha base de datos y el diseño de la red neuronal, incluyendo el ajuste de los hiperparámetros y la evaluación de los resultados obtenidos.

Por otro lado, la elaboración de la memoria también se repartió entre los dos autores. Carla desarrolló los apartados de introducción, contexto y conclusiones. Mientras que Javier trabajó en el estado del arte, metodología y objetivos.

El capítulo 6, llamado *Proyecto piloto*, fue redactado por ambos autores teniendo en cuenta quien desarrolló principalmente el código relacionado con cada subapartado.

Aunque las tareas se hayan repartido entre ambos autores, el desarrollo no se ha llevado a cabo de forma completamente independiente. Tanto la memoria como el código utilizado han sido revisados de manera cruzada, permitiendo a ambos autores aportar ideas y posibles mejoras sobre el trabajo. Por tanto, las divisiones descritas anteriormente indican el autor principal del apartado o código, pero no implican que dichas partes hayan sido desarrolladas únicamente por esa persona. Gracias a las revisiones se han detectado errores, mejoras y ajustes que debían incorporarse con tal de mantener un formato común y asegurar coherencia en el proyecto.

Tabla 1. Organización del trabajo en grupo.

Organización del trabajo en grupo - Desarrollo de la memoria	
Apartado de la memoria	Responsables
Introducción	Alumno 1, Alumno 2
Contexto y estado del arte	Alumno 1, Alumno 2
Objetivos concretos y metodología de trabajo	Alumno 1, Alumno 2
Identificación de requisitos	Alumno 1, Alumno 2
Proyecto piloto	Alumno 1, Alumno 2
Evaluación	Alumno 1, Alumno 2
Conclusiones y trabajo futuro	Alumno 1, Alumno 2

1. Introducción

En diciembre de 2013 comenzó la misión Gaia (Brown et al., 2016) con el objetivo de crear un mapa que permita conocer más detalles del Sistema Solar y la Vía Láctea. Esta misión es considerada la sucesora de Hipparcos dentro de European Space Agency (ESA; Agencia Espacial Europea), siendo este el primer satélite dedicado a la astrometría. Dicha misión fue puesta en marcha en el 1989 y finalizó en el 1993. Los datos que Gaia aporta son 200 veces más precisos que los obtenidos por dicho satélite, pero aun así, de menor calidad que los obtenidos por otros proyectos actuales.

La propia agencia ESA describe en el reporte publicado en 2013 donde explicaban detalles de la misión de Gaia (Clark, 2013) que antes de estudiar un objeto celeste, es necesario poder ubicarlo en el plano, de lo contrario solo tendrían un conjunto de datos sin sentido pertenecientes a un mismo conjunto, pero sin un orden o punto de referencia, en sus propias palabras, describen lo siguiente:

«Antes de que los astrónomos puedan estudiar un objeto celeste, deben saber dónde encontrarlo. Sin este conocimiento, los astrónomos vagarían en vano en lo que Galileo alguna vez llamó un oscuro laberinto»

Por este motivo, la misión principal de Gaia se puede considerar muy útil para continuar desarrollando estudios y conocimientos acerca del universo.

Más allá de este objetivo, Gaia ha podido aportar descubrimientos de objetos celestes que anteriormente no conocíamos. Esta misión ha proporcionado uno de los catálogos más extensos y precisos hasta la fecha (Vallenari et al., 2023), no solo aportando datos astrométricos, sino que también fotométricos y espectrofotométricos.

Otras misiones, como ahora la iniciada en el año 2000 con SDSS, son capaces de proporcionar mediciones con mayor resolución que Gaia, pero con un número de objetos observados y una

cobertura del cielo mucho menores (York et al., 2000). De este hecho parte la idea del trabajo que se desarrolla a continuación.

Si se pudiese definir una similitud entre los espectros obtenidos por Gaia y SDSS, conseguiríamos combinar lo mejor de ambos proyectos, el rango espacial que Gaia ha sido capaz de conseguir junto a la calidad y detalle que SDSS conlleva. En este contexto, gracias a los avances constantes de la inteligencia artificial, en este trabajo proponemos explorar técnicas que nos permitan llevar a cabo este objetivo; convertir espectros de Gaia en su equivalente SDSS.

1.1. Motivación

A lo largo de 2026 se publicarán los últimos datos recolectados por Gaia en un último DR4 y catálogo final DR5. Se calcula que a lo largo de la misión, unos 2 000 millones de estrellas y otros objetos celestes fueron captados por el satélite. Gracias a los datos recolectados, se dispone de una imagen reconstruida sobre cómo un observador vería nuestra galaxia desde el exterior de esta. Esta hazaña se ha conseguido a base de un conjunto de datos donde la información del cuerpo celeste parte fundamentalmente de dos espectros de baja resolución. La espectroscopía es una de las herramientas principales de la astrofísica para extraer información acerca de los cuerpos astronómicos. Gracias a la distribución de la luz en función de la longitud de onda, se pueden conocer detalles clave acerca de los objetos estudiados, como por ejemplo su composición, la temperatura y la gravedad superficial (Recio-Blanco et al., 2016).

La motivación de este trabajo parte de explorar si técnicas de aprendizaje automático pueden aprender a relacionar la gran cantidad de datos captados por Gaia y los espectros de mayor calidad de SDSS. Si se modela la relación entre ambos datos, se conseguiría mejorar la información obtenida a partir de los datos recolectados por Gaia.

1.2. Planteamiento del trabajo

El objetivo principal del trabajo que se desarrolla a continuación es diseñar un modelo basado en redes neuronales que consiga convertir espectros de Gaia en espectros equivalentes a los

de SDSS. De esta forma conseguiríamos encontrar un modelo que relacione los datos captados por ambos proyectos.

Para llevarlo a cabo, primero debemos entender las características de ambas fuentes de información, dado que los datos que usaremos deben estar correlacionados entre ambos conjuntos de datos. En concreto nos centraremos en la tercera liberación de datos de Gaia (Gaia DR3) (Vallenari et al., 2023) y la decimotercera de SDSS (DR13) (Albareti et al., 2017), debido a que estos son los que en el DR3 de Gaia ya encontramos semi comparados, o por lo menos las asociaciones de vecindad hechas. Para ser exactos, trataremos de relacionar los espectros de baja resolución de Gaia DR3 y los espectros ópticos de SDSS DR13.

Para realizar este trabajo seleccionamos el conjunto de datos de Gaia como base de estudio por diferentes motivos, por un lado, estas observaciones son parte de un estudio actual y al mismo tiempo la forma de acceder a los datos es relativamente sencilla, pero por otro, es muy destacable la gran cantidad de información y cuerpos observados que Gaia dispone. Esto nos permite tener una buena base para tratar de sacar comparaciones con otros satélites y al mismo tiempo justifica la magnitud del efecto que tendría su mejora.

1.3. Estructura del trabajo

El resto de este documento se organiza de la siguiente manera:

En el Capítulo 2 se explican los fundamentos teóricos necesarios para entender los espectros estelares y los conjuntos de datos empleados, y se revisa el estado del arte de los modelos generativos y del aprendizaje profundo aplicados a la astronomía.

En el Capítulo 3 se definen el objetivo general y los objetivos específicos del trabajo, así como la metodología seguida para alcanzarlos, aportando detalles acerca de los datos y librerías usadas.

En el Capítulo 4 se identifican los requisitos del sistema desarrollado.

En el Capítulo 5 se describe el proyecto piloto desarrollado: el trabajo realizado en cada etapa de la metodología y la herramienta *software* construida para la extracción de los datos, el entrenamiento del modelo y su puesta en servicio.

En el Capítulo 6 se evalúan los resultados obtenidos por el modelo frente a las observaciones reales de SDSS.

Finalmente, en el Capítulo 7 se recogen las conclusiones del trabajo y se proponen posibles líneas de trabajo futuro.

2. Contexto y estado del arte

En esta sección se dará un contexto al problema anteriormente descrito, comenzando desde la base del conocimiento necesario para entender los datos, hasta las técnicas que se usarán para el desarrollo del modelo de aprendizaje automático.

Por otro lado, también exploraremos trabajos ya publicados que contengan estudios de alta utilidad para el presente.

2.1. Contexto del problema


A continuación nos centraremos en desarrollar términos relativos a los espectros estelares, su interpretación y cómo se obtienen y definen en las bases de datos de cada proyecto.

2.1.1. Espectros estelares

Podemos definir un espectro estelar como la función que relaciona el flujo captado de una estrella en función de la longitud de onda. Gracias a dicha función, se obtiene la distribución de la energía que emite el cuerpo celeste según el rango óptico dado, lo que permite estudiar ciertas características del cuerpo. Por ejemplo, si nos centramos en los picos del gráfico resultante de su representación, se puede analizar la composición del cuerpo o metalicidad, dado que cada elemento emite o absorbe luz en diferentes rangos. Al mismo tiempo, de este dato también se puede estudiar la temperatura en la que se encuentra dicho elemento. Por otro lado, si nos centramos en la anchura de las líneas, hablaríamos de datos como la gravedad superficial. Estas relaciones han sido estudiadas por muchos científicos a lo largo de los años, como por ejemplo Carroll & Ostlie (2017), quienes recogen de forma amplia las áreas principales de la astrofísica.

En la Figura 2.1 se muestra un ejemplo de espectro estelar observado por SDSS, donde se pueden apreciar las líneas de absorción mencionadas.

Figura 2.1. Ejemplo de espectro estelar observado por SDSS



Fuente: Elaboración propia

Algunos estudios trataron de crear herramientas automatizadas para la obtención de los datos anteriormente mencionados. Por ejemplo Lee et al. (2008) lo intentó con la sexta liberación de datos de SDSS.

Paralelamente, en la unidad de control número 8 de Gaia se trata de establecer la misma relación, como se puede observar en el trabajo llevado a cabo por Witten et al. (2023), donde llegaron a identificar de manera detallada la proporción de composición metálica de las estrellas observadas.

Para cuantificar la calidad de las observaciones, se utiliza la relación señal-ruido SNR. Esta medida se expresa como el cociente entre el flujo observado y su error correspondiente. Una [SNR].{acr} baja indica que en los datos observados predomina el ruido, por lo que son poco precisos, mientras que un valor alto indica lo contrario, poco ruido y una mayor precisión. Si definimos el error como σ y suponemos que el error sigue una distribución normal, $F \pm \sigma$ contendría alrededor del 68% de los valores reales, $F \pm 2\sigma$ el 95% y $F \pm 3\sigma$ el 99.7% de los datos. Bajo esta nomenclatura $SNR = F/\sigma$ y el error relativo de un espectro sería su inversa, $error_{relativo} = \sigma/F$, indicando la incertidumbre expresada en porcentaje del tamaño de la muestra

En los siguientes apartados comentaremos los datos espectrales de Gaia y SDSS.

2.1.2. Datos espectrales de Gaia

El satélite Gaia consta de 3 instrumentos para detectar la luz que recogen los telescopios del satélite (Vallenari et al., 2023). El primero, conocido como astrómetro, mide las posiciones estelares en el cielo, el espectrómetro, Radial Velocity Spectrometer (RVS), medirá las velocidades radiales y, por último, el instrumento fotométrico aportará dos espectros de baja resolución de dos bandas ópticas, la azul y la roja. Cabe destacar que, debido al movimiento rotativo de Gaia, se toman unas 70 mediciones fotométricas de cada cuerpo celeste. Estos espectros son preprocesados y tratados por diferentes unidades de coordinación antes de formar parte del conjunto de datos que nosotros usaremos en este trabajo, por lo que el ruido de fondo ya habrá sido reducido significativamente.

El satélite en cuestión se encuentra en una posición espacial conocida como el segundo punto de Lagrange, ubicada a 1,5 millones de kilómetros de la Tierra y donde las fuerzas gravitacionales del Sol, la Tierra y la Luna están en equilibrio. Por otro lado, el satélite, el Sol y la Tierra siempre van a permanecer alineados, impidiendo así que ninguno de los cuerpos celestes mencionados se interponga en el campo de visión de Gaia.

La espectrofotometría en la que nos basaremos durante el desarrollo de este trabajo es la Blue Photometer / Red Photometer (BP/RP), también denominada espectro Espectros conjuntos BP/RP de Gaia (XP). Como hemos comentado, estos datos proceden del fotómetro azul y del rojo, lo que permite cubrir entre los 330 y 680 nm gracias al espectro azul y de los 640 a 1050 nm gracias al rojo (Zhang et al., 2023). Estos datos se representan por aproximadamente 110 elementos efectivos de resolución (De Angeli et al., 2023a), con un poder de resolución variable según la longitud de onda de aproximadamente $R \sim 50 - 160$. Este detalle conlleva que en la tercera liberación de datos de Gaia no obtengamos directamente una tabla de relación flujo - longitud de onda, sino que los espectros vienen dados por coeficientes XP que deben transformarse con ayuda de librerías como *GaiaXPy* (De Angeli et al., 2023b).

2.1.3. Datos espectrales de SDSS

En contraposición a Gaia, este trabajo también usará y analizará datos conseguidos gracias a SDSS, proyecto iniciado con el mismo objetivo que Gaia, crear un mapa tridimensional, pero, a diferencia de este, basado en observaciones terrestres. En este caso, el mapa actual creado gracias a este sondeo contiene más de 930 000 galaxias.

La primera operación bajo el nombre SDSS comenzó en el año 2000, y sigue activo con su quinta fase SDSS-V, que tiene planteado llegar a su fin en 2027 (Gautham Adamane Pallathadka et al., 2025).

Aunque la última publicación de datos de SDSS sea la número 19, tal y como hemos comentado anteriormente, dado que el análisis de cruce de datos de Gaia DR3 se ha llevado a cabo con el DR13 de SDSS, este será usado durante el estudio aunque no pertenezca a la fase más avanzada del proyecto sino a la cuarta.


A diferencia de Gaia, SDSS proporciona directamente espectros ópticos en longitud de onda y flujo, y estos datos se almacenan distribuidos a lo largo de archivos Flexible Image Transport System (FITS). En esta base se pueden encontrar variables como la longitud de onda y el flujo espectral.

Dentro del proyecto de SDSS, el programa Mapping Nearby Galaxies at Apache Point Observatory (MaNGA) se encarga de procesar los datos con tal de crear el mapa estelar, en su artículo original para SDSS-IV (Bundy et al., 2015) encontramos que el rango espectral aproximado de SDSS se mantiene entre los 360 y 1030 nm y su resolución se encuentra en $R \sim 2000$.

2.1.4. Comparativa de los espectros de Gaia y SDSS

Gaia y SDSS comparten gran parte de su rango óptico pero con datos captados con estrategias e instrumentos diferentes. Esto se enfatiza cuando comparamos los espectros observados por cada proyecto acerca del mismo cuerpo celeste. En la Figura 2.2 se muestra un ejemplo aleatorio.

Figura 2.2. Ejemplo aleatorio del espectro captado de un mismo cuerpo por Gaia y SDSS



Fuente: Elaboración propia

Podemos observar como claramente el intervalo que SDSS cubre es muy similar a Gaia, pero existe una gran diferencia en cuanto a la suavidad de las curvas representadas. Como vemos, SDSS incluye muchos más detalles que Gaia, su espectro tiene una resolución superior. Por otro lado, si nos fijamos en los datos captados en los extremos de visión de Gaia, notamos la posibilidad de que en rangos inferiores a 400 nm estemos observando artefactos u obteniendo mediciones muy poco precisas. Lo mismo sucede en valores superiores a 950 nm. Diversos estudios han observado una menor precisión y un error mayor en intervalos muy similares a los mencionados en este trabajo, por ejemplo el artículo de Huang et al. (2024).

A lo largo del trabajo, para garantizar que los datos analizados correspondan al mismo objeto astronómico, se empleará la tabla de cruce oficial de DR3 denominada *gaiadr3.sdssdr13_best_neighbour* que se puede consultar en el archivo de Gaia (Gaia Archive, 2022). Esta tabla contiene para cada cuerpo observado por Gaia, el vecino más cercano en SDSS DR13, es decir, el que cuenta con una mayor probabilidad de que estén describiendo el mismo cuerpo celeste. El procedimiento con el cual se establece esta vecindad se encuentra descrito en la documentación oficial de Gaia DR3 (Gaia Collaboration & European Space Agency, 2023),

que puede consultarse en el propio archivo de Gaia. Dentro de este conjunto, definiremos un umbral de aceptación dado por la distancia angular, fijado en 2 segundos de arco.

2.2. Estado del arte

En los últimos años, la astronomía se ha beneficiado de las técnicas de aprendizaje automático, principalmente en tareas tradicionales como clasificación y agrupamiento. Por ejemplo, Djorgovski et al. (2022) señalan que «una amplia variedad de métodos de clasificación y agrupamiento se ha aplicado a estas tareas, y sigue siendo un área de investigación muy activa». En efecto, muchos esfuerzos han estado enfocados en reconocer tipos de estrellas o galaxias, identificar eventos transitorios, y diferenciar estrellas de galaxias, aprovechando catálogos masivos con miles de características. Estos enfoques basados en aprendizaje automático clásico han permitido lidiar con el flujo de datos de observaciones astronómicas mediante el uso de la clasificación supervisada o el agrupamiento no supervisado.

2.2.1. Modelos generativos en Astronomía

Paralelamente, ha crecido el interés en generar datos astronómicos sintéticos mediante modelos generativos. En particular, las Generative Adversarial Network (GAN; red generativa antagónica) se han aplicado con éxito en algunos contextos. Por ejemplo, García-Jara et al. (2022) propusieron un método de aumento de datos (*data augmentation*) basado en GAN para generar curvas de luz sintéticas de estrellas variables y mostraron cómo su modelo logra producir variaciones realistas de luminosidad, mejorando significativamente la precisión que alcanza la clasificación cuando se entrena con estos datos sintéticos adicionales. Esto ejemplifica cómo las GAN pueden crear nuevos ejemplos de baja complejidad (en este caso series temporales) para compensar la escasez de datos etiquetados.

Asimismo, dada la enorme base de datos espectrales de baja resolución de la misión Gaia (más de 220 millones de espectros BP/RP en Gaia DR3), se han desarrollado modelos generativos específicos para estos datos. Laroche & Speagle (2025) introdujeron un *autoencoder* variacional generativo no supervisado que aprende directamente de los espectros Gaia sin

necesidad de etiquetas estelares. Su arquitectura sigue el esquema *encoder-decoder* propio de los *autoencoders* variacionales: un codificador comprime los coeficientes de los espectros BP/RP en un espacio latente de baja dimensión y un decodificador reconstruye el espectro a partir de dicha representación, entrenándose ambos de forma conjunta mediante la optimización de la Evidence Lower Bound (ELBO; cota inferior de la evidencia). Su modelo reproduce los espectros BP/RP y detecta patrones en áreas donde el aprendizaje supervisado falla debido a la falta de referencias. De hecho, antes de este trabajo la única aproximación generativa para los espectros de Gaia era supervisada: Zhang et al. (2023) entrenaron un modelo capaz de generar el espectro XP a partir de los parámetros estelares, apoyándose para ello en un conjunto reducido de estrellas de Gaia que cuentan con una observación equivalente en el sondeo espectroscópico terrestre LAMOST, del cual se obtuvieron dichos parámetros de referencia. Estos desarrollos recientes demuestran que los modelos generativos pueden explorar el conjunto masivo de datos Gaia para *aproximar* datos de mayor resolución.


2.2.2. Aprendizaje profundo en Astrofísica

A pesar de estos avances, el uso de redes neuronales profundas en astronomía sigue siendo relativamente reciente y sujeto a debate. Ting (2025) destaca que, aunque estas técnicas ofrecen *perspectivas diversas* y capacidades de modelar relaciones complejas, todavía enfrentan retos importantes. Según Ting, la astronomía ha entrado en una era de datos sin precedentes, lo que ha impulsado a muchos investigadores a adoptar métodos de aprendizaje profundo para procesar observaciones modernas. Sin embargo, las reacciones varían: algunos científicos ven estas redes profundas como herramientas transformadoras, mientras que otros se muestran escépticos sobre sus verdaderas ventajas. En este contexto, se advierte que aunque las arquitecturas neuronales pueden incorporar sesgos físicos (simetrías, leyes de conservación) en su diseño para generalizar mejor, sigue siendo necesario evaluar cuidadosamente sus resultados. En resumen, el aprendizaje profundo en astrofísica está emergiendo como una vía prometedora que aún se encuentra en una fase exploratoria y que requiere una validación rigurosa antes de tener una aceptación generalizada en este dominio.

Dentro de las evoluciones recientes encontramos el trabajo Grassi et al. (2026), en el que se explora la integración de modelos físicos dentro de arquitecturas de aprendizaje automático, mediante el desarrollo de un modelo geométrico 3D completamente diferenciable para la interpretación de cubos de datos espectrales moleculares. Mediante el uso de librerías de diferenciación automática como JAX, generaron observaciones sintéticas a partir de campos de densidad y velocidad parametrizados, optimizándolos iterativamente para reproducir con precisión las observaciones astronómicas reales. Aunque este enfoque orientado a la física difiere de las redes neuronales generativas utilizadas para relacionar directamente las bandas fotométricas con espectros de alta resolución, subraya la importancia de emplear modelos computacionales avanzados y generación sintética de datos para sortear las limitaciones instrumentales y extraer propiedades subyacentes de las señales astrofísicas, especialmente para la comprensión de la composición química de los objetos celestes radiando dichas señales.

El ejemplo más cercano al enfoque propuesto en este trabajo lo encontramos en un trabajo muy reciente de Haghjoo et al. (2026). En esta propuesta, se usó el conjunto de datos de JWST Advanced Deep Extragalactic Survey (JADES) (Curtis-Lake et al., 2025) que proporciona imágenes y espectroscopía profunda combinando observaciones de la cámara (NIRCam) y el espectrógrafo (NIRSpec) del James Webb Space Telescope (JWST). Este sondeo es ideal para el estudio porque observa los mismos objetivos de galaxias utilizando una combinación de espectroscopía de prisma de baja resolución ($R \sim 30\text{--}300$) y modos de red de difracción de media resolución ($R \sim 1000$; mediante los instrumentos G140M, G235M y G395M). A partir de estas observaciones emparejadas, los investigadores seleccionaron una muestra inicial de 1 187 pares de espectros coincidentes, la cual fue ampliada posteriormente a 24 927 muestras mediante técnicas de mejora de datos (*data augmentation*) para el entrenamiento del modelo, tal y como se ilustra en la Figura 2.3.

Figura 2.3. Ejemplo del procedimiento de mejora de datos aplicado a un par de espectros JADES de baja y alta resolución: sobre el espectro original (negro) se generan veinte realizaciones sintéticas (líneas de color) mediante desplazamientos aleatorios del corrimiento al rojo y perturbaciones de flujo.



Fuente: Haghighi et al. (2026)

Este planteamiento guarda un notable paralelismo con el que se persigue en el presente trabajo: en ambos casos se dispone de observaciones reales emparejadas del mismo objeto en baja y en alta resolución, y el objetivo es entrenar un modelo que aprenda a recuperar el detalle de la observación de alta resolución a partir de la de baja resolución. La diferencia principal reside en la escala y naturaleza de los datos de partida: mientras que Haghighi et al. (2026) contaban únicamente con 1 187 pares reales y recurrieron a la mejora de datos para ampliar el conjunto de entrenamiento, en este trabajo se dispone de decenas de miles de pares reales de espectros Gaia-SDSS, lo que permite abordar el problema directamente con los datos observados sin necesidad de generar realizaciones sintéticas adicionales.

Para llevar a cabo este estudio, los investigadores desarrollaron una red neuronal profunda personalizada de tres etapas, diseñada específicamente para procesar datos unidimensionales. La primera etapa emplea una red neuronal convolucional residual (1D ResNet-CNN) que genera una reconstrucción preliminar y conservadora del espectro. La segunda etapa utiliza otra red convolucional para inferir el corrimiento al rojo (*redshift*), contextualizando así la posición física

de los elementos. Finalmente, la tercera etapa de refinamiento divide el trabajo en dos ramas: un modelo basado en mecanismos de atención (*Transformer encoder*) que procesa de manera aislada las líneas de emisión, y otra red convolucional que ajusta suavemente el continuo del espectro. En total, esta arquitectura por fases cuenta con unos 2,5 millones de parámetros y está diseñada para aplicar correcciones basadas en la física, evitando que la Inteligencia Artificial (IA) «alucine» datos inexistentes.

Los resultados demostraron que este modelo es capaz de recuperar con éxito detalles de alta resolución a partir de observaciones de baja calidad. El sistema logró desmezclar y separar de manera efectiva líneas de emisión que aparecían fusionadas en los datos originales (como el doblete de [O III] y H β), mejorando sistemáticamente la relación señal-ruido en todas las líneas de diagnóstico clave. Además, los espectros superresueltos generados por la IA alcanzaron niveles de ruido comparables a las observaciones reales de alta resolución y permitieron realizar estimaciones del corrimiento al rojo mucho más precisas, reduciendo a la mitad la dispersión de errores y disminuyendo significativamente los casos atípicos frente a los datos de entrada.

2.3. Conclusiones

La integración y estandarización de catálogos astronómicos masivos representa un desafío técnico fundamental, especialmente al trabajar con fuentes de naturalezas distintas como Gaia y SDSS. Mientras que Gaia provee un volumen de datos astrométricos, fotométricos y espectroscópicos sin precedentes, sus espectros BP/RP operan en resoluciones bajas y requieren complejos procesos de calibración para mitigar el ruido espacial y las fluctuaciones. Cabe matizar que el espectrómetro RVS de Gaia alcanza una resolución incluso mayor que la de SDSS, pero al requerir estrellas más brillantes dispone de muchas menos fuentes observadas. En contraste, SDSS aporta espectros ópticos de mayor resolución que los BP/RP. La necesidad de interconectar ambas misiones define el núcleo de este estudio: establecer una relación sólida

capaz de traducir y equiparar los espectros de baja resolución de Gaia con los espectros de mayor resolución de SDSS.

Para abordar este asunto, el análisis del estado del arte evidencia una transición desde el uso de estas herramientas únicamente para clasificación o agrupamiento clásico hacia el uso de las GAN y los *autoencoders* variacionales, que recientemente han demostrado su utilidad para la generación de datos sintéticos realistas y se establecen ya como herramientas útiles para la calibración y otras áreas relevantes en el estudio astronómico.

Avanzando aún más allá, el éxito reciente en la mejora de resolución de datos del telescopio JWST mediante modelos generativos muestra que la aplicación de estas técnicas representa una solución viable que puede ser también aplicada en el contexto del catálogo astronómico que ofrece Gaia.

El propósito de la propuesta planteada en este documento es profundizar en la aplicación de estas técnicas novedosas ofreciendo soluciones útiles que aporten mejoras tangibles en el ámbito de la astronomía, específicamente para la mejora de las señales contenidas en el amplio catálogo que Gaia nos ofrece.

3. Objetivos concretos y metodología de trabajo

En este capítulo se detalla el objetivo principal de este trabajo y su desglose en objetivos más específicos para alcanzarlo.

También se expone la metodología empleada para afrontar dichos objetivos.

3.1. Objetivo general

El objetivo general de este trabajo consiste en desarrollar un modelo basado en aprendizaje automático que permita aproximar el flujo calibrado captado por los fotómetros de baja resolución BP/RP de Gaia a un espectro de resolución más alta, similar al proporcionado por las observaciones de mayor calidad de SDSS.

3.2. Objetivos específicos

Para alcanzar el objetivo propuesto, se deben alcanzar previamente los siguientes objetivos intermedios.

- Análisis estructural de la base de datos de Gaia y SDSS:

El análisis y comprensión de las observaciones y la manera en la que están organizadas en los repositorios de Gaia y SDSS es fundamental para entender cuales son los datos relevantes a extraer.

Es también necesario comprender la relación entre las mediciones de ambos sondeos astronómicos para usar observaciones coincidentes, referidas a los mismos objetos del catálogo de objetos celestes.

- Preselección de los datos:

Una vez se ha ganado cierta comprensión de los datos, se puede hacer una valoración más precisa de cuál es la calidad de los mismos, y qué valores no reúnen los requisitos para incluirse en el conjunto de datos de entrenamiento.

Así, se deben definir unos parámetros para excluir los datos menos relevantes para el objetivo principal.

- Extracción de los datos:

Tras haber comprendido qué servicios se pueden usar para la extracción de los datos y haber reducido el conjunto de entrada atendiendo a su calidad, el siguiente paso consiste en la extracción de los mismos, usando métodos que optimicen la descarga de los datos orientados a minimizar el tiempo y los posibles errores que los servicios ofrecidos por los proyectos de Gaia y SDSS ofrecen.

- Preprocesado de los datos:

Una vez extraídos los datos, es necesario realizar cierto preprocesado de los mismos para mejorar el entrenamiento.

Puesto que en la preselección de las observaciones se han tenido en cuenta criterios de calidad, y Gaia DR3 ofrece datos ya procesados y relaciones con SDSS, el preprocesado en este caso consiste en la reducción del ruido, mejorando así la SNR, aplicada a las observaciones de SDSS, que tienen más variabilidad y pueden así aumentar la complejidad del entrenamiento.

- Preparación de los conjuntos de entrenamiento, test y validación:

Una vez los datos están listos, es necesario realizar el reparto entre los distintos conjuntos de datos. En concreto se necesitará un conjunto de entrenamiento para encontrar los mejores parámetros de los modelos propuestos, un conjunto de validación para seleccionar el modelo con mejores resultados y tener indicativos en caso de sobreajuste y, finalmente, un conjunto de test con el que estimar la calidad del modelo seleccionado a partir de datos no observados previamente.

- Selección del modelo de redes neuronales más adecuado:

Para el caso expuesto se considera que las redes neuronales pueden aportar una solución novedosa gracias a su no-linealidad.

- Entrenamiento, refinamiento y validación del modelo:

La red neuronal entrenada requerirá de un proceso de optimización y ajuste de los hiperparámetros para dar una solución satisfactoria. Asimismo, se llevará un proceso de validación de los resultados a partir del conjunto de datos creado.

- Puesta en servicio del modelo:

Una vez ajustado el modelo, el objetivo será proporcionar una manera sencilla e intuitiva de acceder a él.

3.3. Metodología de trabajo

De acuerdo a los objetivos expuestos, la metodología empleada para desarrollar este trabajo se estructura en las siguientes etapas. Las particularidades y la implementación concreta de cada una de ellas se recogen en el Capítulo 5.

1. Análisis exploratorio de los datos: mediante cuadernos *Jupyter* colaborativos se estudia la organización de los repositorios de Gaia y SDSS, los servicios disponibles para su consulta y la manera de emparejar las observaciones de ambos proyectos referidas a un mismo objeto celeste.
2. Preselección de los datos: a partir del análisis previo se definen filtros de calidad sobre el cruce de catálogos, con el objetivo de maximizar la fiabilidad de los pares de espectros utilizados.
3. Extracción de los datos: descarga por lotes de los espectros emparejados, de manera reproducible y tolerante a las limitaciones de los servicios públicos de consulta. Esta etapa parte deliberadamente del catálogo espectroscópico de SDSS y no del cruce fotométrico de Gaia, ya que este último constituyó inicialmente el cuello de botella del proceso: al buscar el espectro de SDSS correspondiente a cada fuente fotométrica de Gaia, más del 98% de los candidatos carecían de una observación espectroscópica real, dejando un conjunto de datos prácticamente vacío. Invertiendo el sentido de la consulta —partiendo de SDSS y buscando

la contrapartida en Gaia— se garantiza que cada candidato dispone de espectro desde el inicio, lo que eleva la tasa de coincidencia con Gaia a un 20-50%, muy por encima del 1% obtenido con el planteamiento original.

4. Preprocesado de los datos: limpieza de anomalías y artefactos, y homogeneización de los espectros de ambas fuentes para que sean directamente comparables. En esta etapa se compara la SNR de los espectros: cada observatorio puede medir el mismo objeto un número distinto de veces y en condiciones diferentes, por lo que la SNR puede variar entre observaciones de un mismo cuerpo. Por ello, los pares de espectros que se usen para entrenar y evaluar el modelo deben presentar una SNR equivalente.
5. Preparación de los conjuntos de entrenamiento, validación y test: partición del conjunto de datos garantizando una distribución homogénea de las muestras, también en términos de SNR, y de manera reproducible.
6. Entrenamiento, refinamiento y validación del modelo: proceso iterativo de optimización y ajuste de hiperparámetros, evaluando el modelo sobre el conjunto de validación y reservando el conjunto de test para la evaluación final.

4. Descripción del experimento

En este capítulo se describe el trabajo realizado en cada una de las etapas definidas en la metodología.

4.1. Definición de los requisitos

Para un correcto desarrollo del experimento, es necesario garantizar una serie de requisitos mínimos. Estos se describen a continuación según el ámbito al que hacen referencia.

4.1.1. Requisitos del conjunto de datos

El conjunto de datos usado para el entrenamiento del modelo debe estar formado por pares de espectros de Gaia y SDSS que correspondan al mismo objeto astronómico. Para garantizar esta correspondencia se debe usar el catálogo de cruce de datos que Gaia incluye en su tercera liberación de datos, en concreto, la tabla de mejores vecinos entre Gaia DR3 y SDSS DR13.

Cada muestra usada debe contener, como mínimo, el identificador de este objeto dentro de su base de datos, el espectro, la malla de longitud de onda correspondiente y la relación señal-ruido del espectro. En el caso de SDSS el SNR será obtenido a partir de la variable *ivar*. El identificador del objeto dependerá de la base de datos, ya que en Gaia será suficiente con el *source_id*, mientras que en SDSS se necesitará *specObjID*, *plate*, *mjd* y *fiberID* que hacen referencia al identificador único del objeto en la base de datos de SDSS, el número de placa usada en la observación, la fecha de observación y el número de fibra dentro de la placa asignada al objeto observado.

El conjunto de datos original deberá ser almacenado en un formato que sea eficiente para su uso en el modelo. En este trabajo se consideró el formato HDF5, ya que permite organizar en un solo fichero todos los datos necesarios para su entrenamiento.


Por último, será necesaria la aplicación de criterios de calidad y el preprocesado del conjunto de datos a usar.

4.1.2. Requisitos de calidad

Una vez extraído el conjunto de datos inicial, las parejas de espectros deberán pasar una serie de requisitos mínimos de calidad para ser usados en el entrenamiento del modelo.

En primer lugar, los espectros deberán contener valores numéricos válidos en todo el rango usado, con lo que se descartarán aquellos datos que contengan valores nulos o infinitos. Del mismo modo, se descartarán aquellas observaciones que contengan posibles anomalías en el flujo, como por ejemplo picos extremos o que no encajen en la tendencia general de la muestra. Al mismo tiempo, también se descartará el caso contrario, muestras donde haya una clara falta de variabilidad en el flujo, es decir, por ejemplo, que este sea un valor constante. Un claro ejemplo se puede observar en la Figura 4.1, donde se aprecia como el espectro captado por SDSS es nulo:

Figura 4.1. Ejemplo de espectros donde el espectro de SDSS es constante 0.




Fuente: Elaboración propia

Por otro lado, las parejas de espectros de Gaia y SDSS deberán ser coherentes en cuanto a la escala del flujo. Aunque ambos instrumentos presentan resoluciones diferentes, al tratarse de observaciones hechas al mismo cuerpo estelar, la relación entre los flujos no debe situarse en valores extremos. Para descartar aquellas muestras que no sean coherentes, se comparará la media del flujo de ambos espectros y se descartarán aquellos pares cuya relación se encuentre

fuera de los límites definidos con el percentil 99 del conjunto de datos. En la Figura 4.2 encontramos un ejemplo de lo que se evitará gracias a esta restricción.

Figura 4.2. Ejemplo de espectros donde la escala de Gaia y SDSS es diferente.



Fuente: Elaboración propia

En gran parte de los descartes que se realizarán, se usarán los percentiles 95 o 99 para establecer los límites tolerables. Al definirlos de esta forma, no se escogerá un valor arbitrario fijo, sino que se tendrá en cuenta el comportamiento estadístico de la muestra, permitiendo extender su uso en casos futuros.

Asimismo, deberá tenerse en cuenta la SNR de las observaciones. Este dato indica la calidad de la señal respecto al ruido, por lo que si este valor es muy bajo, la información del espectro asociado es poco fiable. Respecto a esto, se impondrán dos criterios: por un lado, se descartarán aquellos datos con los valores de SNR por debajo del percentil 1. Por otro, dado que el modelo tratará de aprender la correspondencia entre las observaciones de Gaia y SDSS y estos observan los objetos de formas diferentes y no bajo las mismas condiciones, las mediciones pueden presentar niveles de ruido diferentes aun tratándose del mismo cuerpo celeste, por lo que se descartarán aquellos pares en los que la relación entre la media de SNR de ambos instrumentos sean mayores al percentil 95 o inferiores al 5.

Finalmente, los espectros se recortarán a los rangos de longitud de onda comunes entre Gaia y SDSS y así se evitará que la generación de datos de salida se vea afectada por la falta de datos de entrada. Al mismo tiempo, se descartarán los intervalos iniciales y finales del rango espectral, ya que en estas zonas suelen aparecer con mayor frecuencia anomalías u observaciones de artefactos. En concreto, se restringirá el intervalo de entrenamiento entre los 500 y 900 nm.

4.1.3. Requisitos del modelo

El modelo basado en redes neuronales debe resolver un problema de regresión multivariante, en el que la entrada sea un vector de flujo de Gaia y la salida se corresponda con el espectro de SDSS.

Para mejorar la estabilidad del entrenamiento, el modelo debe trabajar con datos normalizados tanto de entrada como de salida. La normalización será aplicada teniendo en cuenta solo los datos de entrenamiento. Los de validación y test no deben ser usados para entrenar el modelo, con la finalidad de que sean observaciones completamente nuevas para evaluarlo.

La separación de los grupos de entrenamiento, validación y test deberá llevarse a cabo de forma aleatoria para garantizar la variabilidad dentro de las muestras usadas para entrenar y evaluar el modelo. El objetivo de esta separación aleatoria es que los conjuntos sean estadísticamente equivalentes, es decir, el conjunto de entrenamiento debe ser representativo de los conjuntos de validación y test.

La arquitectura y diseño del modelo deberá tener capacidad suficiente como para aprender las relaciones entre el espectro de entrada y salida, pero sin llegar a memorizar el conjunto de entrenamiento para así evitar el sobreajuste.

El modelo deberá evaluarse con métricas cuantitativas apropiadas al tipo de dato y al mismo tiempo con un análisis visual de los resultados.

4.2. Preparación del conjunto de datos

La construcción del conjunto de datos de entrenamiento se ha automatizado mediante un flujo reproducible y tolerante a fallos, organizado en seis etapas encadenadas. Cada etapa consume el resultado de la anterior y guarda su salida en disco de inmediato, de manera que una ejecución interrumpida puede reanudarse desde la primera etapa incompleta sin repetir el trabajo ya realizado. A grandes rasgos dicho flujo obtiene la referencia de los objetos con espectro en SDSS, localiza la contrapartida de cada uno en Gaia, descarga los espectros para los objetos referenciados de SDSS, depura el listado conservando solo los pares completos, obtiene los espectros calibrados de Gaia y combina ambas fuentes en un único conjunto de datos listo para su uso en el ajuste de la red neuronal.

4.2.1. Obtención de los objetos con espectro de SDSS

La primera etapa parte del catálogo espectroscópico de SDSS y recopila los metadatos de todos sus espectros primarios. Comenzar por este catálogo garantiza que cada objeto considerado dispone realmente de una observación espectral de SDSS, lo que evita la enorme pérdida de muestras que se produciría al partir del cruce fotométrico en sentido contrario. El resultado es la lista de candidatos con espectro de SDSS confirmado.

4.2.2. Cruce inverso con Gaia

A partir de esa lista, la segunda etapa consulta el archivo de Gaia en sentido inverso: para cada objeto de SDSS busca la fuente equivalente en Gaia que además disponga de espectro BP/RP. La búsqueda se realiza localizando el identificador fotométrico de cada objeto de SDSS en la tabla de cruce oficial *gaiadr3.sdssdr13_best_neighbour*, descrita en la sección de conjuntos de datos, y aplicando el umbral de aceptación de 2 segundos de arco de distancia angular allí definido; de las fuentes así emparejadas se conservan solo aquellas que publican el espectro BP/RP continuo. Así se conserva únicamente la intersección de cuerpos observados por ambos proyectos, que constituye el cruce sobre el que se trabajará.

4.2.3. Descarga de los espectros de SDSS.

La tercera etapa descarga el espectro de SDSS para cada objeto emparejado. Las descargas se realizan en paralelo y cada espectro se almacena en cuanto se obtiene, de modo que el proceso es robusto frente a las interrupciones y a las limitaciones de los servicios públicos de consulta.

4.2.4. Depuración de referencias

Como no todas las descargas culminan con éxito, la cuarta etapa depura el listado de pares y conserva exclusivamente aquellos cuyo espectro de SDSS se ha obtenido correctamente. El resultado es la tabla de referencia definitiva que vincula cada objeto entre ambos sistemas.

4.2.5. Espectros calibrados de Gaia

La quinta etapa recupera los espectros de Gaia de los objetos ya depurados. Dado que Gaia no proporciona directamente la relación entre flujo y longitud de onda, sino una representación mediante coeficientes, en esta etapa dichos espectros se calibran para obtener el flujo continuo equivalente y poder usarlo en el modelo.

4.2.6. Transformación a datos de entrenamiento

Finalmente, la sexta etapa homogeneiza y combina ambas fuentes: los espectros de SDSS se remuestrean a una rejilla común de longitudes de onda y se guardan junto a los de Gaia correspondientes en un único fichero con un formato optimizado HDF5. Este fichero es además acumulativo, de forma que sucesivas ejecuciones incorporan los pares nuevos sin descartar los ya almacenados.

Este proceso de extracción ha permitido reunir un conjunto de datos real con más de 55 000 pares de espectros emparejados de Gaia y SDSS.

4.2.7. Análisis visual de los datos obtenidos

Para analizar la distribución física de los datos usados en el entrenamiento del modelo, se usa una representación del diagrama Hertzsprung-Russell (HR) (Hertzsprung-Russell, Hertzsprung (1911) y Russell (1914)). Este diagrama representa la relación entre la luminosidad de las estrellas (eje Y) y su temperatura o color (eje X).

En concreto, se considera la fuente de datos de Gaia. En el eje horizontal se grafica la variable bp_rp , que corresponde al índice de color obtenido a partir de la diferencia entre las medias de las magnitudes de BP y RP. Cuanto menor sea este valor, más azul y caliente será la estrella, mientras que los valores mayores representan estrellas rojas y frías.

En el eje vertical encontramos la variable $phot_g_mean_mag$, la magnitud media aparente en la banda G, que indica lo brillante que se aprecia la estrella en las observaciones realizadas. Este valor depende de variables como por ejemplo la distancia, por lo que para convertirlos a la misma escala y obtener la magnitud absoluta de cada observación, se usó el paralaje de cada una.

La fórmula usada parte de la representación del diagrama HR realizada en el trabajo de Gaia Collaboration et al. (2018). En este artículo se usa la siguiente fórmula para representar todas las observaciones en la misma escala:

$$M_G = G + 5 + 5 \log_{10} \left(\frac{\varpi}{1000} \right) \quad (4.1)$$

Aplicando las propiedades de los logaritmos a la fórmula anterior:

$$M_G = G + 5 + 5[\log_{10}(\varpi) - \log_{10}(1000)] \quad (4.2)$$

Como $\log_{10}(1000) = 3$, se obtiene:

$$M_G = G + 5 + 5 \log_{10}(\varpi) - 15 \quad (4.3)$$

y, simplificando la expresión :


$$M_G = G + 5 \log_{10}(\varpi) - 10 \quad (4.4)$$

Donde G corresponde $phot_g_mean_mag$ y ϖ es el paralaje expresado en milisegundos de arco.

Tras esta modificación, aquellas estrellas más luminosas, presentan valores más bajos incluso negativos, mientras que las menos luminosas se mantienen en valores más altos y positivos.

El diagrama de los datos usados en este estudio es el que se observa en la Figura 4.3:

Figura 4.3. Diagrama HR de las observaciones de Gaia contenidas en la base de datos



Fuente: Elaboración propia

En este apreciamos como el conjunto de datos no está formado por un único tipo de estrella, sino que presenta objetos con propiedades físicas diferentes. Si bien es cierto, destaca un grupo mayoritario tal y como se aprecia en la parte media izquierda del gráfico. Debido a esta


diversidad, el modelo debe adaptarse a fuentes de distintas características, con lo que no es un entrenamiento especializado en un solo tipo de estrella. Al mismo tiempo, se observan algunos datos dispersos y distantes de las regiones más ocupadas, los cuales podrían considerarse anomalías para el modelo a entrenar.

4.3. Análisis de la SNR de los datos obtenidos

Una vez creado y filtrado el conjunto de datos, para analizar la calidad de los espectros, se usó la SNR y el error relativo. En primer lugar, para los espectros de Gaia, se calculó a partir del flujo y de la incertidumbre proporcionada por la librería *GaiaXPy*. La mediana obtenida fue de 20.04, representando un error relativo del 5%. Para SDSS, la SNR se calculó a partir del flujo y la varianza inversa, definiendo el error como $\sigma = 1/\sqrt{\text{ivar}}$. Para calcular la relación entre el flujo y el ruido, se descartaron los valores donde *ivar* era cero. De este cálculo, se obtuvo un error relativo del 2.9% y un SNR de 34.76.

Observamos a continuación en la Figura 4.4 la distribución del SNR en los espectros de Gaia y SDSS.

Figura 4.4. Distribución de la SNR de los espectros de Gaia y SDSS




Fuente: Elaboración propia

En esta gráfica se puede observar la distribución del valor mediano de SNR de los espectros del conjunto de datos. Se puede apreciar como SDSS tiene una distribución centrada en valores más grandes, mientras que Gaia se ubica en valores inferiores. Esta observación era la esperada dadas las características de ambos instrumentos.

Por otro lado, valoramos el error relativo mediano según la longitud de onda. En la Figura 4.5 se aprecian los valores obtenidos para Gaia.

Figura 4.5. Distribución del error relativo según la longitud de onda de los espectros de Gaia




Fuente: Elaboración propia

La evolución del error relativo no es uniforme. Cerca de los 6500 Å se observa un salto, coincidiendo con el rango en el que se solapan las mediciones de BP y RP. Esta discontinuidad puede deberse al proceso con el que se solapan ambos espectros, y por lo tanto no se considera una característica de los espectros. Además, cabe destacar que los valores menores se encuentran en la zona del salto, alcanzando el mínimo sobre los 6400 Å. Después del salto, en el que el error incrementa bruscamente, el error relativo vuelve a disminuir y parece mantenerse constante en la zona central del RS, volviendo a aumentar en las longitudes de onda más elevadas. Asimismo, los percentiles 25 y 75 indican que la variabilidad es más alta en la zona del salto que en los extremos de la longitud espectral analizada y menor cerca del final del rango del BS.

En la Figura 4.6 encontramos la distribución de SDSS.

Figura 4.6. Distribución del error relativo según la longitud de onda de los espectros de SDSS




Fuente: Elaboración propia

A diferencia de Gaia, el error relativo se mantiene mayormente constante a lo largo de todo el intervalo estudiado, teniendo una tendencia creciente a partir de los 8000 Å. Por otro lado, el mínimo se alcanza entre los 6000 y 7500 Å. A partir de los 9000 Å la mediana es más inestable y la banda de los percentiles 25 y 75 se ensancha. Este dato implica que los datos son menos precisos en el extremo rojo del flujo.

Sobreponiendo el espectro del mismo objeto observado por Gaia y SDSS con su respectiva banda +-error, obtenemos gráficos como los observados en la Figura 4.7.

Figura 4.7. Ejemplos de los espectros observados por Gaia y SDSS con bandas de error



Fuente: Elaboración propia

En estos se observa como la banda de error de Gaia tiende a ser más ancha y constante, mientras que SDSS tiene picos donde la imprecisión es destacable.

4.4. Entrenamiento del modelo

Una vez se dispone de la base de datos con los pares de espectros de Gaia y SDSS, se procedió con el preprocesamiento de los datos, diseño y entrenamiento del modelo de redes neuronales. El objetivo es conseguir un modelo que aprenda una transformación entre los datos de entrada de Gaia y el espectro de SDSS asociado. Así pues, el modelo planteado recibe como

entrada un vector con el flujo de Gaia y obtiene como salida un vector con una aproximación del flujo correspondiente al espectro de SDSS.

De cara a la preparación de la base para el entrenamiento del modelo, se definieron 3 subconjuntos: entrenamiento, test y validación. El 80% de los datos se usó para el entrenamiento del modelo, mientras que el 20% restante fue dividido de forma aleatoria entre los conjuntos de test y validación, siendo cada uno un 10% de los datos originales.

4.4.1. Planteamiento general del entrenamiento

Para encontrar el modelo óptimo, se realizaron diversas pruebas con tal de analizar como afectaban al rendimiento del modelo. En primer lugar, se probaron diferentes funciones de normalización para facilitar el entrenamiento de la red neuronal, ya que las variables de entrada y salida se situaban en escalas similares cercanas al 1 y las funciones de pérdida se ubicaban en valores de más fácil interpretación. Como punto de partida, se aplicó una normalización global a través de la media y desviación típica de los datos del conjunto de entrenamiento. Esta opción no proporcionó malos resultados (tal y como podremos observar en los próximos apartados) y tenía la ventaja de que se podía deshacer la normalización sin necesidad de conocer los valores del conjunto de test, pero al tratarse de un proceso demasiado generalizado para la variabilidad de valores de los espectros, se probaron otros enfoques. Por ejemplo, se consideró la normalización espectro a espectro, en el que cada flujo se normaliza en su propia escala con la mediana de sus datos o su máximo.

Las diferentes pruebas de normalización se realizaron durante el ensayo del modelo neuronal denso, dado que era el más simple y rápido de entrenar para poder observar los resultados de pequeñas modificaciones como esta. Una vez se definió la normalización más efectiva, fue usada en modelos posteriores.

Probamos también la adición de los datos de la relación señal-ruido del espectro de Gaia como parte del conjunto de entrada. En este caso, los resultados obtenidos no mejoraron significativamente, por lo que se descartó y continuó el estudio sin este dato de entrada.

4.4.2. Modelo base: red neuronal densa

Después de un procedimiento de prueba y error, el modelo que mejores resultados obtuvo dentro en la categoría de red neuronal densa, estaba formado por una capa de entrada del tamaño de los datos de Gaia, varias capas intermedias (una con 512 neuronas y tres más con 1024) y finalmente una capa de salida con tantos puntos como el espectro de SDSS a predecir. Además, se probaron diferentes funciones de activación, siendo ELU y LeakyReLU las que obtuvieron mejores resultados debido a que no anulan completamente las neuronas con valores negativos. En el problema de regresión al que nos enfrentamos, las desviaciones pueden ser positivas y negativas respecto a la media, así que el uso de los métodos mencionados anteriormente favorecía el aprendizaje.

La función de pérdida definida fue Huber (Huber, 1964), que combina el error cuadrático medio para errores pequeños, y el error absoluto medio para errores más grandes. La función matemática que la define es la siguiente:

$$L_{\delta}(a) = \begin{cases} \frac{1}{2}a^2, & \text{si } |a| \leq \delta \\ \delta(|a| - \frac{1}{2}\delta), & \text{si } |a| > \delta \end{cases} \quad (4.5)$$

En esta, a representa el error entre el valor real y predicho, y δ define el valor frontera en el que la función deja de estar definida como Mean Squared Error (MSE) y pasa a ser más similar a Mean Absolute Error (MAE). En este caso, se definió δ como 1.

Este comportamiento permite rebajar la penalización en aquellos casos en los que los espectros tengan desviaciones anómalas que no deban definir el comportamiento del modelo. Se consideró el optimizador Adam (Kingma & Ba, 2014) con una tasa de aprendizaje de 0.0001 y una limitación a 1 en la norma de los gradientes con el objetivo de evitar las actualizaciones excesivas.

El entrenamiento se realizó con lotes de 64 muestras y un máximo de 50 épocas. Para evitar un sobreentrenamiento del modelo, definimos una función de parada temprana que monitorea la pérdida del set de validación y detiene el entrenamiento si después de 5 épocas no ha mejorado

como mínimo un 0.0001. De la misma forma, añadimos una función de disminución de la tasa de aprendizaje cuando la variable controlada durante el entrenamiento se estanca durante dos épocas.

4.4.3. Modelo convolucional

Como segunda arquitectura se planteó un modelo basado en capas convolucionales de una dimensión. La motivación de este enfoque reside en la propia naturaleza de los espectros: las estructuras que los caracterizan, como las líneas de absorción y emisión o la forma local del continuo, son patrones locales que pueden aparecer en cualquier punto del rango de longitudes de onda. Las convoluciones explotan precisamente esta localidad, ya que aplican los mismos filtros a lo largo de todo el espectro, lo que reduce drásticamente el número de parámetros respecto a una red densa y favorece que el modelo generalice los patrones aprendidos en una zona del espectro a las demás.

De esta arquitectura se desarrollaron dos versiones: el modelo convolucional 1D, una red residual de campo receptivo local, y el modelo convolucional U-Net, que amplía el campo receptivo a todo el espectro e incorpora la información de incertidumbre de ambos instrumentos.

4.4.3.1. Modelo convolucional 1D

El diseño sigue un planteamiento de superresolución análogo al de la primera etapa del modelo de Haghjoo et al. (2026). En primer lugar, el espectro de Gaia se interpola linealmente sobre la malla de longitudes de onda de SDSS, obteniendo así una versión de baja resolución alineada punto a punto con la salida esperada. La red recibe este espectro interpolado y aprende únicamente la corrección que debe aplicarse sobre él, gracias a una conexión residual global que suma la entrada interpolada a la salida de la red. De esta forma el modelo no necesita aprender la forma general del continuo, que ya viene dada por la interpolación, y puede concentrar su capacidad en recuperar el detalle espectral que la resolución de Gaia no capta.

En cuanto a la arquitectura interna, el modelo se compone de una capa convolucional inicial de 64 filtros con un núcleo de tamaño 9, seguida de cuatro bloques residuales. Cada bloque

contiene dos convoluciones de 64 filtros con núcleo de tamaño 7 y activación ELU, junto con un atajo que suma la entrada del bloque a su salida para facilitar la propagación del gradiente. Una última capa convolucional con un único filtro y núcleo de tamaño 5 genera la corrección final. En total, la red cuenta con aproximadamente 230 000 parámetros entrenables, una cifra muy inferior a la del modelo denso descrito anteriormente.

Respecto a la normalización, en este caso ambos espectros del par se escalan con la mediana del flujo del espectro de Gaia. Al depender únicamente de la entrada, esta estrategia permite deshacer la normalización de la predicción sin necesidad de conocer el espectro real de SDSS, lo que resulta imprescindible al aplicar el modelo sobre observaciones nuevas.

El resto de la configuración del entrenamiento se mantuvo idéntica a la del modelo base: función de pérdida Huber con $\delta = 1$, optimizador Adam con tasa de aprendizaje de 0.0001 y limitación a 1 de la norma de los gradientes, lotes de 64 muestras, un máximo de 50 épocas y las mismas funciones de parada temprana y reducción de la tasa de aprendizaje.

4.4.3.2. Modelo convolucional U-Net

Como veremos en el apartado de evaluación, el modelo convolucional 1D se estanca en una corrección suave del espectro interpolado. La segunda versión ataca las causas de ese estancamiento incorporando la información de incertidumbre de ambos instrumentos, que hasta ahora no se utilizaba, mediante tres mejoras:

1. **Pérdida ponderada por la varianza inversa de SDSS.** El espectro objetivo no es el espectro verdadero de la estrella, sino una observación con ruido, y ese ruido varía mucho entre píxeles. Ponderando la pérdida de Huber con la varianza inversa de cada píxel, los puntos ruidosos del objetivo pesan menos y los píxeles marcados como inválidos por SDSS (varianza inversa nula) quedan enmascarados, de modo que la red aprende el espectro subyacente y no la realización concreta del ruido. Los pesos se reescalan con la normalización de cada espectro, se ajustan para que su media sobre los píxeles válidos sea 1 (así todos los objetos contribuyen por igual y los pesos solo redistribuyen la importancia entre píxeles) y se

recortan superiormente para evitar que unos pocos píxeles de varianza muy baja dominen el entrenamiento.

2. **Canal de entrada adicional con el error de flujo de Gaia.** Junto al flujo interpolado, la red recibe el error observacional de Gaia interpolado sobre la misma malla, lo que le permite saber qué zonas de su entrada son fiables y modular la corrección en consecuencia.
3. **Mejora de datos con ruido realista.** En cada época se perturba el flujo de Gaia con ruido gaussiano de amplitud igual a su error observacional, lo que multiplica de forma efectiva el conjunto de entrenamiento y obliga a la red a ser robusta frente al nivel de ruido real del instrumento. Para que esta perturbación sea estadísticamente correcta, se aplica sobre la malla nativa de Gaia y la interpolación se realiza después, en cada época, expresada como una matriz lineal fija dentro del propio flujo de datos de entrenamiento.

La arquitectura evoluciona de la pila de bloques residuales a una U-Net de una dimensión (Ronneberger et al., 2015). El codificador parte de una convolución inicial de 64 filtros y encadena tres niveles de submuestreo por convolución con paso 2 (64, 96, 128 y 160 filtros); el cuello de botella aplica dos bloques residuales que ven el espectro completo a un octavo de su resolución; y el decodificador recupera la resolución original en tres niveles de sobremuestreo, concatenando en cada uno la conexión del nivel equivalente del codificador. Cada bloque residual incorpora además atención de canal de tipo *squeeze-and-excitation* (Hu et al., 2018), que recalibra la importancia relativa de los filtros en función del contenido global del espectro. Con los tres niveles de submuestreo, el campo receptivo cubre todo el rango de longitudes de onda, por lo que la red puede corregir tanto el detalle de las líneas como el desajuste de continuo a gran escala entre Gaia y SDSS, algo fuera del alcance del campo receptivo local del modelo 1D. Se mantiene la conexión residual global sobre el espectro interpolado, y el modelo alcanza aproximadamente 2,3 millones de parámetros entrenables, una capacidad muy superior a la del modelo convolucional 1D aunque todavía del orden de la mitad que la del modelo denso.

La configuración del entrenamiento conserva la función de pérdida Huber con $\delta = 1$ (ahora ponderada por píxel), las mismas métricas MAE y MSE sin ponderar para mantener la comparabilidad con el resto de modelos, el optimizador Adam con limitación a 1 de la norma de los gradientes y los lotes de 64 muestras. Al ser un modelo de mayor capacidad, se amplió el presupuesto de entrenamiento: tasa de aprendizaje inicial de 0.0003, un máximo de 100 épocas, parada temprana con paciencia de 10 épocas y reducción de la tasa de aprendizaje a la mitad tras 4 épocas sin mejora.

4.4.4. Modelo recurrente

Además de las estructuras anteriormente mencionadas, se evaluaron modelos recurrentes. En estos, cada espectro se consideró como una secuencia en función de la longitud de onda, donde cada longitud de onda era un paso de la secuencia, y el flujo correspondiente era la variable de entrada. Esta arquitectura permite conservar información de pasos anteriores de la secuencia (Schmidt, 2019).

Los primeros intentos de arquitectura recurrente se basaron en capas recurrentes simples y Gated Recurrent Unit (GRU). En los primeros intentos, las funciones de pérdida, optimizador y parada temprana se mantuvieron igual que las descritas en las redes neuronales densas, dado que habían presentado un buen funcionamiento con estos modelos. Pero finalmente se redujo las épocas de espera dado que la diferencia entre esperar 2 o 4 épocas no reflejaba mejoras en las estadísticas pero sí en el tiempo de entrenamiento.

La arquitectura usada para los modelos más simples incorporaban capas densas similares a las que anteriormente habían sido definidas pero con la adición de una capa recurrente simple de dimensión 128, o dos capas de GRU de dimensión 128 consecutivas, configurando la primera como *return_sequences = True* para que devolviese la representación de cada punto y la otra como *False* para que devolviese el último estado de la secuencia y que este vector fuese usado como entrada a las capas densas.

Por otro lado, se probaron variantes bidireccionales de la arquitectura recurrente (Schuster & Paliwal, 1997). Esta capa procesa la secuencia de puntos en ambos sentidos, en sentido creciente y decreciente de longitud de onda. Se incluyeron versiones con y sin capas de normalización internas.

Finalmente, se evaluaron arquitecturas con mecanismos de atención (Vaswani et al., 2017), permitiendo que no se resuma el entrenamiento en el último estado recurrente, sino que el modelo conserva información de todos los pasos de la secuencia y asigna pesos a aquellas regiones del espectro que se consideran más importantes para la predicción.

En todas las arquitecturas probadas, la capa de salida del modelo tenía dimensión igual al número de puntos del espectro real de SDSS.

5. Descripción de los resultados

Una vez entrenadas las distintas opciones de red neuronal, es necesario evaluar el rendimiento para determinar que aproximación es la más adecuada al problema que se ha planteado.

Para hacerlo, se considerarán diversos caminos. Por un lado, se analizarán las métricas obtenidas durante el entrenamiento, como por ejemplo los valores de la función de pérdida, MAE o MSE. No obstante, debe tenerse en cuenta que se han usado diferentes funciones de normalización, por lo que no en todos los casos estas métricas se podrán comparar directamente.


Para evitar este problema, la evaluación se basará también en otras técnicas. La primera será una comparativa visual de los espectros respecto al real de SDSS tras deshacer la normalización, esto permitirá comprobar si el modelo se ajusta correctamente a la forma global del espectro y a sus zonas de emisión y absorción.

Por último, se empleará la librería *ISpec* (Blanco-Cuaresma et al., 2014) para estimar parámetros físicos de los objetos observados, como por ejemplo la temperatura efectiva o la gravedad superficial. El objetivo será comparar los datos obtenidos con las predicciones y el espectro real. De esta forma no se valorará solo la similitud de los espectros por sí mismos, sino que también se tendrá en cuenta si las predicciones se aproximan a la información astrofísica que se obtiene del espectro de SDSS original.

5.1. Resultados obtenidos con el modelo base

Durante el entrenamiento del modelo basado en capas densas con normalización a partir de la mediana global de los datos, se pudo observar una evolución estable de las métricas controladas, tanto en el conjunto de entrenamiento como el de validación. Vemos esta disminución constante representada en la Figura 5.1.

Figura 5.1. Gráfica de la evolución del MAE en el modelo de redes neuronales densas con normalización global.




Fuente: Elaboración propia

En la última época llevada a cabo, se obtuvo una pérdida del conjunto de entrenamiento muy similar a la del conjunto de validación. Una vez finalizado el entrenamiento del modelo, se evaluó su eficacia sobre el conjunto de test. Los valores obtenidos fueron muy cercanos a los de la muestra de validación y entrenamiento, reforzando la idea de que el modelo tiene un comportamiento estable ante los datos que no han sido vistos con anterioridad.

Cabe destacar que las métricas calculadas se definen sobre espectros normalizados, por lo que no mantienen la escala de las unidades de flujo originales. Sin embargo, su uso ha sido necesario para poder valorar de forma comprensible la eficacia de los diferentes modelos estudiados.

En las gráficas detalladas de la Figura 5.2, se muestran dos ejemplos distintos donde se observan superpuestos los datos de entrada del modelo, es decir el espectro captado por Gaia, el espectro de SDSS real y el generado a partir del modelo entrenado. Las observaciones representadas formaron parte del conjunto de test.

Figura 5.2. Ejemplos de espectros generados por el modelo de redes neuronales densas con normalización basada en la mediana del conjunto de entrenamiento.



Fuente: Elaboración propia


Por un lado, en azul encontramos el espectro que el modelo pretende predecir, los puntos de SDSS una vez han sido recortados. Por otro, en verde podemos ver la entrada que recibe el modelo, siendo esta el espectro calibrado de Gaia. Los puntos de Gaia han sido convertidos a la misma unidad de medida de flujo que SDSS para poder representar ambos espectros en la

misma gráfica, pero en los datos originales, se usan escalas diferentes. Finalmente, en naranja encontramos el espectro predicho por el modelo.

En gran parte de los gráficos observados, el modelo reproduce la morfología general del espectro, incluso modela los picos más acentuados. Si bien es cierto, hay puntos que no puede inferir debido a las estructuras detalladas de SDSS y la baja resolución inicial de Gaia. Durante las comparaciones que se harán a continuación, siempre se usarán los mismos objetos, identificados por los id que aparecen en los gráficos recientemente comentados.

Por otro lado, al usar una normalización basada en la mediana por espectro, los resultados obtenidos fueron similares. Incluso las épocas avanzaron de forma similar tal y como observamos en las gráficas representadas en las imágenes Figura 5.3.


Figura 5.3. Gráficas de evolución de las métricas de entrenamiento en la red densa.



Fuente: Elaboración propia

Tampoco se apreciaron rasgos de sobreajuste en el modelo, y los espectros obtenidos sobre las mismas observaciones que el modelo anterior fueron las observadas en la Figura 5.4:

Figura 5.4. Ejemplos de espectros generados por el modelo de redes neuronales densas con normalización basada en la mediana de cada espectro.




Fuente: Elaboración propia

Comparándolas con las gráficas obtenidas con la primera normalización mencionada, podemos destacar una diferencia visual pequeña, pero positiva hacia este segundo tipo de normalización.

Por último, si nos fijamos en las figuras Figura 5.5, observamos los resultados obtenidos sobre el mismo objeto con una normalización espectro a espectro basada en el máximo valor del flujo:

Figura 5.5. Ejemplos de espectros generados por el modelo de redes neuronales densas con normalización basada en el máximo de cada espectro.



Fuente: Elaboración propia

A partir de las gráficas observadas, parece que la opción con mejores resultados es la segunda, dado que es la que obtiene espectros más cercanos a los reales. Ahora bien, comprobemos métricas para obtener resultados más concluyentes.

En la Tabla 5.1 se encuentran las métricas obtenidas con esta arquitectura según el tipo de normalización aplicado.

Tabla 5.1. Resultados obtenidos con distintas estrategias de normalización.

Normalización	Pérdida	MAE	MSE
Mediana del conjunto de entrenamiento	0.0094	0.0769	0.0211
Por mediana de cada espectro	0.0032	0.0423	0.0091
Por máximo de cada espectro	0.0048	0.0625	0.0097

Fuente: Elaboración propia

Igual que en la conclusión anterior, parece que al aplicar una normalización por espectro basada en la mediana, obtenemos ligeramente mejores resultados.

La última comparación vendrá dada por la librería *iSpec*. Con esta estimamos los parámetros astrofísicos de los cuerpos observados a partir del espectro real de SDSS y los predichos. Para ello primero transformamos cada espectro en el formato requerido por *iSpec*, teniendo que añadir para cada punto el flujo, longitud de onda y error asociado. El análisis se realizó sin incertidumbre asignada a cada punto, con lo que se asignó un valor unitario de error a todos los puntos de modo que todos partiesen del mismo peso. Una vez teníamos la estructura requerida, normalizamos al continuo los espectros con la función propia de *iSpec*.

Además, los puntos iniciales de testeo de las variables *teff*, *logg* y *mh* se definieron a partir de las observaciones de Gaia para facilitar el entrenamiento y no partir siempre de unos valores por defecto en todos los espectros.

En primer lugar, se realizó el ajuste con la malla de modelos atmosféricos *MARCS.GES*, pero se observaron advertencias de que los valores quedaba fuera del rango disponible, así que se usó *ATLAS9.Castelli*, que eliminó el problema. Estas mallas atmosféricas incluyen modelos teóricos


de atmósferas estelares, describiendo el comportamiento atmosférico de las estrellas bajo diferentes condiciones de temperatura, gravedad y metalicidad. Por otro lado, la lista de líneas atómicas usada fue *VALD*, cuyo contenido identifica las líneas espectrales con los elementos a los que pertenecen. Se usaron las abundancias solares de Grevesse como referencia de la metalicidad y la información isotópica de *SPECTRUM*.

A partir de los datos iniciales, mallas e información base mencionada, se ajustó la temperatura, gravedad superficial y metalicidad de las estrellas.

Para comprobar el funcionamiento del modelo de redes neuronales, se tomó los resultados del espectro real de [SDSS].{acr} como los verdaderos, y se comparó los predichos con estos, calculando las diferencias entre los datos obtenidos, sus errores absolutos y relativos.

Analizamos muestras aleatorias de 250 espectros para cada modelo denso. El resultado se resume en las gráficas observadas en las figuras Figura 5.6.

Figura 5.6. Gráficos de barras de errores absolutos respecto iSpec entre los espectros reales de SDSS y los predichos.




Fuente: Elaboración propia

Encontramos destacada la mediana de los valores obtenidos y la distribución en histogramas de los errores de cada espectro.

Se aprecia como la mediana del error de la temperatura se ubica en todos los modelos alrededor del 0.25%, mientras que la de la gravedad superficial cerca del 0.10% y el error absoluto de la temperatura cerca de los 0.017. Estos valores indican una relación de similitud entre las propiedades físicas de ambos espectros, por lo que podemos afirmar que los modelos densos estudiados conllevan una alta capacidad para predecir los espectros de SDSS manteniendo las características astrofísicas predichas con iSpec en rangos de error pequeños.

Al tratar de añadir la SNR de las muestras de Gaia como parte de los datos de entrada del modelo, los resultados obtenidos sobre los mismos objetos fueron los observados en las gráficas Figura 5.7.

Figura 5.7. Ejemplos de espectros generados por el modelo de redes neuronales densas con la variable SNR como entrada.



Fuente: Elaboración propia

Por otro lado, las métricas obtenidas se encuentran en la Tabla 5.2:

Tabla 5.2. Resultados obtenidos incluyendo la SNR de la muestra de Gaia como entrada del modelo.

Pérdida	MAE	MSE
0.0031	0.0424	0.0089

Fuente: Elaboración propia

Se puede apreciar como la incorporación de la SNR como variable adicional de entrada no produce una mejora significativa en el modelo. Los valores de pérdida, MAE y MSE son prácticamente los mismos a los obtenidos en pruebas anteriores y visualmente tampoco se aprecia una mejora de la captación de tendencias del espectro. Por este motivo, se decidió no incluir esta variable en el modelo final.


5.2. Resultados obtenidos con los modelos convolucionales

Se presentan por separado los resultados de las dos versiones del modelo convolucional: el modelo convolucional 1D y el modelo convolucional U-Net. Ambas comparten la misma normalización (la mediana del flujo de Gaia de cada par), por lo que, a diferencia de lo que ocurre con el modelo denso, sus métricas sí son directamente comparables entre sí.

5.2.1. Modelo convolucional 1D

En el caso del modelo convolucional residual, el entrenamiento se detuvo en la época 11 por la función de parada temprana. La evolución de las métricas, representada en la Figura 5.8, muestra un descenso muy rápido durante las dos primeras épocas seguido de un estancamiento, a pesar de las sucesivas reducciones de la tasa de aprendizaje aplicadas durante el proceso.

Figura 5.8. Gráficas de las métricas de evolución de entranamiento en modelo convolucional 1D



Fuente: Elaboración propia

Este comportamiento sugiere que la red converge casi de inmediato hacia una solución cercana al propio espectro interpolado, aportando sobre él únicamente una corrección pequeña. Las curvas de entrenamiento y validación permanecen muy próximas entre sí durante todo el proceso, por lo que tampoco en esta arquitectura se aprecian indicios de sobreajuste.

Una vez finalizado el entrenamiento, se evaluó el modelo sobre el conjunto de test, obteniendo las métricas recogidas en la Tabla 5.3, muy similares a las del conjunto de validación.

Tabla 5.3. Resultados obtenidos sobre el conjunto de test con el modelo convolucional 1D.


Pérdida	MAE	MSE
0.0153	0.1137	0.0352

Fuente: Elaboración propia

Cabe recordar que estas métricas se calculan sobre espectros normalizados con la mediana del flujo de Gaia, una estrategia distinta a las empleadas en el modelo denso, por lo que los valores no son directamente comparables con los de las tablas anteriores.

En la Figura 5.9 se muestran las predicciones obtenidas sobre los mismos objetos empleados en las comparativas del modelo denso, una vez deshecha la normalización.

Figura 5.9. Ejemplos de espectros generados por el modelo convolucional 1D.



Fuente: Elaboración propia


En ambos ejemplos se observa que el espectro predicho se mantiene muy próximo a la entrada de Gaia interpolada, aplicando sobre ella una corrección suave que ajusta la escala local del

continuo. Sin embargo, el modelo no llega a reconstruir las estructuras finas del espectro de SDSS, en línea con el estancamiento temprano observado durante el entrenamiento.

5.2.2. Modelo convolucional U-Net

El comportamiento del modelo U-Net durante el entrenamiento fue muy distinto al del modelo convolucional 1D. Lejos de estancarse en las primeras épocas, la pérdida de validación siguió mejorando de forma sostenida: la función de reducción de la tasa de aprendizaje llegó a actuar cuatro veces (de 0.0003 hasta 0.000019) y cada reducción desbloqueó una nueva fase de mejora. El entrenamiento se interrumpió en la época 48, cuando la pérdida de validación llevaba varias épocas prácticamente estabilizada; gracias al guardado del mejor modelo en cada época, se conservan los pesos de la época 47, la de mejor validación. La evolución de las métricas se muestra en la Figura 5.10 donde de nuevo las curvas de entrenamiento y validación permanecen próximas entre sí, sin indicios de sobreajuste.

Figura 5.10. Gráficas de la evolución de las métricas de entrenamiento del modelo convolucional U-Net



Fuente: Elaboración propia

Las métricas obtenidas sobre el conjunto de test se recogen en la Tabla 5.4. Junto a las métricas sin ponderar, comparables con las del resto de modelos, se incluyen sus variantes ponderadas

por la varianza inversa de SDSS, que reflejan el objetivo que la red optimiza. La pérdida, al estar ponderada, no es comparable con la de las arquitecturas anteriores.


Tabla 5.4. Resultados obtenidos sobre el conjunto de test con el modelo convolucional U-Net.

Pérdida	MAE	MSE	MAE ponderado	MSE ponderado
0.0055	0.0786	0.0165	0.0704	0.0112

Fuente: Elaboración propia

La comparación con la Tabla 5.3 es directa por compartir normalización: el MAE sobre test baja de 0.1137 a 0.0786 (una mejora del 31 %) y el MSE de 0.0352 a 0.0165 (un 53 %). En la Figura 5.11 se muestran las predicciones sobre los mismos objetos de las comparativas anteriores.

Figura 5.11. Ejemplos de espectros generados por el modelo convolucional U-Net.



Fuente: Elaboración propia

A diferencia del modelo convolucional 1D, la U-Net no se limita a una corrección suave del continuo: la predicción reconstruye parte de la estructura espectral fina del espectro de SDSS, incluidas líneas de absorción que no son visibles en la entrada de Gaia interpolada. Este salto cualitativo es coherente con las mejoras introducidas: el campo receptivo global permite

corregir el continuo a todas las escalas, y la pérdida ponderada concentra la capacidad del modelo en los píxeles fiables del objetivo en lugar de en reproducir su ruido.

5.3. Resultados obtenidos con el modelo recurrente

Después de entrenar diversas combinaciones de las características descritas para los modelos en el apartado de redes recurrentes, podemos destacar 3 modelos que obtuvieron los mejores resultados entre los estudiados.

La primera arquitectura destacable, formada por una capa de GRU y dos densas con función de activación ReLU, junto a las mismas funciones de disminución de la tasa de aprendizaje y parada temprana que los modelos basados únicamente en redes neuronales densas. Después de 23 épocas se obtuvieron las métricas de entrenamiento, validación y test descritas en la Tabla 5.5:

Tabla 5.5. Resultados obtenidos con el primer modelo basado en GRU para los diferentes conjuntos de datos.


Conjunto de datos	Pérdida	MAE	MSE
Entrenamiento	0.0045	0.0482	0.0119
Validación	0.0045	0.0485	0.0138
Test	0.0045	0.0486	0.0123

Fuente: Elaboración propia

Se puede observar como no se aprecian diferencias significativas entre los grupos, pudiendo confirmar la inexistencia de sobreajuste al conjunto de entrenamiento.


Respecto a las predicciones realizadas sobre las mismas observaciones que en los casos anteriores, obtenemos las figuras Figura 5.12 y Figura 5.13 :

Figura 5.12. Ejemplo 1 del espectro generado por el modelo de redes neuronales recurrentes con una capa de GRU.



Fuente: Elaboración propia

Figura 5.13. Ejemplo 2 del espectro generado por el modelo de redes neuronales recurrentes con una capa de GRU.



Fuente: Elaboración propia

Los siguientes modelos a mencionar, usaron funciones de parada temprana con espera de 2 épocas y reducción de la tasa de aprendizaje con 1 época.

La siguiente arquitectura usó una capa Bidireccional después de la de entrada, y a continuación, 4 capas densas con capas de funciones de activación ReLU.

Las métricas obtenidas tras el entrenamiento de las 6 épocas del modelo fueron los incluidos en la Tabla 5.6 :

Tabla 5.6. Resultados obtenidos con el modelo basado en RNN bidireccionales para los diferentes conjuntos de datos.


Conjunto de datos	Pérdida	MAE	MSE
Entrenamiento	0.0047	0.0513	0.0124
Validación	0.0048	0.0540	0.0146
Test	0.0048	0.0533	0.0129

Fuente: Elaboración propia

Estos valores son muy similares a los obtenidos en el modelo anterior, siendo entre un 0.001 y 0.01 más altos según la métrica. Siguen siendo buenas aproximaciones e indicando un buen comportamiento del modelo, pero no presentan una mejora significativa comparado con el anterior.

Los ejemplos usados para la representación visual de las aproximaciones, tampoco presentan grandes diferencias, tal y como observamos en las figuras Figura 5.14

Figura 5.14. Ejemplos de espectros generado por el modelo de redes neuronales recurrentes con una capa bidireccional.



Fuente: Elaboración propia

El último modelo destacable de los estudiados en este apartado, se basa en dos capas Bidireccionales y la aplicación de la función de Atención sobre todos los puntos del espectro junto a las capas densas anteriormente mencionadas. Esta adición tampoco representa grandes mejoras en las métricas del modelo. Los valores pueden observarse en la Tabla 5.7.


Tabla 5.7. Resultados obtenidos con el modelo basado en RNN bidireccionales y la función de Atención para los diferentes conjuntos de datos.

Conjunto de datos	Pérdida	MAE	MSE
Entrenamiento	0.0048	0.0510	0.0127
Validación	0.0047	0.0502	0.0143
Test	0.0046	0.0506	0.0127

Fuente: Elaboración propia

Igual que en las métricas comentadas, en los espectros usados como punto de control tampoco se aprecian grandes diferencias como se puede observar en las imágenes de la Figura 5.15.

Figura 5.15. Ejemplos de espectros generados por el modelo de redes neuronales recurrentes con una función de Atención.



Fuente: Elaboración propia

Por último, si nos basamos en los resultados obtenidos de la estimación de características astrofísicas con *iSpec*, las diferencias entre los valores predichos con los espectros de SDSS reales y los predichos por los modelos son los incluidos en la Tabla 5.8:

Tabla 5.8. Resultados obtenidos con iSpec en los modelos destacados basados en RNNs.

Modelo	Error relativo de T_{eff}	Error relativo de $\log(g)$	Error absoluto de M/H
GRU	0.24%	0.09%	0.014dex
Bidireccional	0.32%	0.11%	0.019dex
Atención	0.21%	0.10%	0.019dex

Fuente: Elaboración propia

De estos resultados se aprecia que las arquitecturas con GRU básicas y Atención presentan mejores resultados que el modelo con solo una capa Bidireccional.

6. Discusión

Para comparar la eficacia de cada modelo estudiado, se cuantificó la diferencia entre los espectros reales de SDSS y los predichos por cada modelo a partir del cálculo de chi-cuadrado para cada observación en el conjunto de test. La fórmula usada se basó en la diferencia entre el flujo real y el flujo predicho, ponderada con la varianza inversa (*ivar*). Al considerar esta definición, los puntos espectrales con una incertidumbre menor, tienen más peso en el cálculo, mientras que los puntos con mayor rango de error, contribuyen en menor medida en el resultado.

La fórmula de chi-cuadrado se define como :

$$\chi^2 = \sum_{i=1}^N (F_{\text{real},i} - F_{\text{pred},i})^2 \text{ivar}_i \quad (6.1)$$

donde $F_{\text{real},i}$ y $F_{\text{pred},i}$ representan, respectivamente, el flujo real y predicho en el punto espectral i , respectivamente, mientras que ivar_i es la varianza inversa sacada de los datos de SDSS.

Por otro lado, como χ^2 también depende del número de puntos de cada espectro, se consideró una versión normalizada dividida por la cantidad de puntos espectrales válidos (con *ivar* mayor que 0). Al normalizarla, facilita la comparación entre los distintos espectros, dado que valores próximos a la unidad indican que las diferencias entre ambos espectros son comparables a la incertidumbre de la muestra, mientras que valores mayores implican discrepancias superiores a las esperadas en los puntos espectrales. Teniendo esto en cuenta, la fórmula final fue:

$$\chi_{\text{norm}}^2 = \frac{\chi^2}{N} \quad (6.2)$$

A partir de la cual se obtuvieron los valores de la Tabla 6.1:

Tabla 6.1. Chi-cuadrado normalizado aplicado sobre los conjuntos de test predichos por los diversos modelos estudiados.

Modelo	Mediana	Mínimo	Máximo
Densa con mediana	1.4	0.47	131.91
Densa con máximo	5.66	0.55	69488.31
RNN con capa de GRU	1.80	0.52	192.86
RNN con capa Bidireccional	2.26	0.66	270.30
RNN con capa de Atención	2.00	0.54	199.19

Fuente: Elaboración propia

Los resultados obtenidos demuestran que la arquitectura densa normalizada con la mediana de cada espectro es la que mejor comportamiento tiene. Los modelos recurrentes no mejoraron este resultado, aunque la arquitectura con una capa de GRU se queda muy próxima. Por otro lado, el modelo denso normalizado con el máximo de cada espectro es la menos estable tal y como se aprecia en la diferencia entre el mínimo y máximo. Presenta una mediana 4 veces superior al modelo con mejores datos, confirmando que es el peor de los modelos destacados en el entrenamiento.

La conclusión extraída con el estadístico chi-cuadrado es la misma que la obtenida de las métricas de entrenamiento y test de los modelos. Si bien es cierto, las diferencias no son muy grandes, pero los valores más pequeños se encuentran en el modelo denso normalizado con la mediana. En cuanto a iSpec, los resultados indican que todos los modelos tienen un comportamiento similar en cuanto a los datos que este aproxima, así que no podemos destacar un modelo en concreto, pero sí afirmar que las predicciones producen datos astrofísicos muy parecidos a los que producen los espectros reales.

7. Conclusiones y trabajo futuro

En este capítulo se incluyen las conclusiones obtenidas tras el desarrollo del trabajo y comentarios acerca de posibles trabajos futuros partiendo de los resultados obtenidos.

7.1. Conclusiones

A lo largo del trabajo hemos llevado a cabo todo el desarrollo necesario para poder entrenar un modelo de redes neuronales, partiendo desde la creación de la base de datos de espectros de Gaia y SDSS hasta su uso para la validación del modelo generado.

En primer lugar, la creación de la base de datos resultó no ser algo trivial. Diseñamos un proceso por etapas que nos permitió obtener a partir de espectros y datos de SDSS, la información captada por Gaia del cuerpo que categorizaba como el vecino más cercano. Se observaron diversas limitaciones en este proceso, en gran medida debido a la estructura y capacidad de los servicios de consulta que disponen ambos instrumentos. Por este motivo, una parte importante del trabajo se basó en conseguir un método robusto y reproducible que nos permitiese crear la base de datos inicial. Al mismo tiempo, la calidad de los pares de espectros también influyó en el estudio, se tuvieron que descartar algunos datos debido a escalas incompatibles, artefactos, relaciones señal-ruido de mala calidad o valores completamente anómalos, como por ejemplo con espectros constantes o nulos a lo largo de la longitud de onda observada.

En cuanto al modelo neuronal, planteamos un problema de regresión multivariante, cuya red recibe como entrada un espectro de Gaia y tiene el objetivo de predecir como salida un espectro de SDSS.

Se evaluaron diferentes arquitecturas de modelo y preprocesamientos de la base de datos, considerando definitivas las versiones que se pueden encontrar detalladas en este trabajo. De dicho proceso de prueba y error, obtuvimos resultados que demuestran que el modelo es capaz de predecir la forma general de los espectros de SDSS en gran parte de los casos. Asimismo, la comparación de las métricas de entrenamiento, validación y test permiten asegurar que el

modelo no se ha sobreajustado a los datos usados durante el entrenamiento, sino que presenta capacidad para generalizar su uso sobre datos no observados.

En resumen, podemos concluir que este trabajo demuestra la viabilidad de diseñar un modelo de redes neuronales capaz de aproximar espectros captados por Gaia a una representación similar a los observados por SDSS. Este hecho permite dejar una puerta abierta a varias líneas de mejora, las cuales serán comentadas en el siguiente apartado.

7.2. Trabajo futuro

Los resultados obtenidos en este estudio constituyen un punto de partida para diversas líneas de mejora. Por ejemplo, una primera opción sería refinar y ampliar la base de datos de entrenamiento. En este trabajo hemos conseguido construir un conjunto de 50 000 parejas de espectros Gaia-SDSS, pero como el rendimiento y la calidad del modelo dependen directamente de dicha base, cuanto mejor selección e investigación de los datos usados, mejores resultados se obtendrían.

Otra opción consistiría en entrenar modelos especializados para distintos tipos de objetos o rangos de parámetros físicos. En este estudio se ha empleado un único modelo global que debía aprender relaciones espectrales para todos los objetos incluidos en el conjunto de datos. Sin embargo, si la base de datos se separase tratando de agrupar aquellos espectros más similares en diversos subconjuntos, la calidad del modelo final podría aumentar dado que facilitaríamos su aprendizaje.

Durante el trabajo se consideró la posibilidad de incluir la relación señal ruido como uno de los parámetros de entrada del modelo. Si bien es cierto, este hecho no produjo mejoras significativas a los resultados obtenidos, pero es una opción a tener en cuenta como posible línea de exploración. Añadiendo esta información se podría valorar la exactitud de cada punto de los espectros observados por Gaia y SDSS, lo que permitiría valorar de forma más precisa el error cometido por el modelo.

Finalmente, la idea de este estudio podría extenderse a otros conjuntos de datos astronómicos. Este proyecto se centró en la liberación de datos número tres de Gaia y la treceava de SDSS debido a sus plataformas y el cruce de datos previamente existente, pero la metodología desarrollada podría aplicarse de forma general a otros catálogos de datos astronómicos. En este trabajo, el objetivo principal era conseguir mejorar la calidad de los datos captados por Gaia, a partir de una herramienta que los aproximase a las observaciones de SDSS. Esto podría generalizarse a otros satélites o telescopios que presenten el mismo problema que nuestro conjunto de datos de entrada, una baja resolución. Generalizando los resultados obtenidos, el modelo no solo transformaría Gaia en SDSS, sino que podría servir como base para mejorar las observaciones precedentes instrumentos astronómicos.

Referencias bibliográficas

- Albareti, F. D., Allende Prieto, C., Almeida, A., Anders, F., Anderson, S., Andrews, B. H., & others. (2017). The Thirteenth Data Release of the Sloan Digital Sky Survey: First Spectroscopic Data from the SDSS-IV Survey Mapping Nearby Galaxies at Apache Point Observatory. *The Astrophysical Journal Supplement Series*, 233(2), 25. <https://doi.org/10.3847/1538-4365/aa8992>
- Bick, A., Blandin, A., & Deming, D. J. (2026). The rapid adoption of generative AI. *Management Science*.
- Blanco-Cuaresma, S., Soubiran, C., Heiter, U., & Jofré, P. (2014). Determining stellar atmospheric parameters and chemical abundances of FGK stars with iSpec. *Astronomy & Astrophysics*, 569, A111. <https://doi.org/10.1051/0004-6361/201423945>
- Brown, A. G. A. and, Vallenari, A., Prusti, T., Bruijne, J. H. de, Mignard, F., Drimmel, R., Babusiaux, C., Bailer-Jones, C. A., Bastian, U., Biermann, M., Evans, D. W., Eyer, L., Jansen, F., Jordi, C., Katz, D., Klioner, S. A., Lammers, U., Lindegren, L., Luri, X., ... Zschocke, S. (2016). <i>Gaia</i> Data Release 1: Summary of the astrometric, photometric, and survey properties. *Astronomy & Astrophysics*, 595, A2. <https://doi.org/10.1051/0004-6361/201629512>
- Bundy, K., Bershady, M. A., Law, D. R., Yan, R., Drory, N., MacDonald, N., Wake, D. A., Cherinka, B., Sánchez-Gallego, J. R., Weijmans, A.-M., Thomas, D., Tremonti, C., Masters, K., Coccato, L., Diamond-Stanic, A. M., Aragón-Salamanca, A., Avila-Reese, V., Badenes, C., Falcón-Barroso, J., & al. (2015). Overview of the SDSS-IV MaNGA Survey: Mapping Nearby Galaxies at Apache Point Observatory. *The Astrophysical Journal*, 798(1), 7. <https://arxiv.org/abs/1412.1482>
- Carroll, B. W., & Ostlie, D. A. (2017). *An Introduction to Modern Astrophysics* (2.^a ed.). Cambridge University Press.

- Clark, S. (2013). *Gaia: El censo galáctico de la ESA. BR-296*. https://esamultimedia.esa.int/docs/science/BR-296-Spanish_Gaia_05_WEB.pdf
- Curtis-Lake, E., Cameron, A. J., Bunker, A. J., Scholtz, J., Carniani, S., Parlanti, E., D'Eugenio, F., Jakobsen, P., Willmer, C. N., Arribas, S., & others. (2025). JADES Data Release 4 Paper I: Sample Selection, Observing Strategy and Redshifts of the complete spectroscopic sample. *arXiv preprint arXiv:2510.01033*.
- De Angeli, F., Weiler, M., Montegriffo, P., Evans, D. W., Riello, M., Andrae, R., Carrasco, J. M., Busso, G., Burgess, P. W., Cacciari, C., Davidson, M., Harrison, D. L., Hodgkin, S. T., Jordi, C., Osborne, P. J., Pancino, E., Altavilla, G., Barstow, M. A., Bailer-Jones, C. A. L., ... Yoldas, A. (2023a). Gaia Data Release 3. Processing and validation of BP/RP low-resolution spectral data. *Astronomy & Astrophysics*, 674, A2. <https://doi.org/10.1051/0004-6361/202243680>
- De Angeli, F., Weiler, M., Montegriffo, P., Evans, D. W., Riello, M., Andrae, R., & others. (2023b). Gaia Data Release 3: Processing and validation of BP/RP low-resolution spectral data. *Astronomy & Astrophysics*, 674, A2. <https://doi.org/10.1051/0004-6361/202243680>
- Djorgovski, S. G., Mahabal, A., Graham, M. J., Polsterer, K., & Krone-Martins, A. (2022). Applications of AI in Astronomy. *arXiv preprint arXiv:2212.01493*.
- Gaia Archive. (2022,). *Gaia DR3: SDSS DR13 Best Neighbour table (gaiadr3.sdssdr13_best_neighbour)*. <https://doi.org/10.17876/gaia/dr.3>
- Gaia Collaboration, & European Space Agency. (2023). *Gaia Data Release 3 Documentation*. <https://gea.esac.esa.int/archive/documentation/GDR3/>
- Gaia Collaboration, Babusiaux, C., Leeuwen, F. van, Barstow, M. A., & others. (2018). Gaia Data Release 2: Observational Hertzsprung-Russell diagrams. *Astronomy & Astrophysics*. <https://doi.org/10.1051/0004-6361/201832843>

- Gaia Collaboration, Brown, A. G. A., Vallenari, A., Prusti, T., Bruijne, J. H. J. de, & others. (2021). Gaia Early Data Release 3: Summary of the contents and survey properties. *Astronomy & Astrophysics*, 649, A1. <https://doi.org/10.1051/0004-6361/202039657>
- García-Jara, G., Protopapas, P., & Estévez, P. A. (2022). Improving astronomical time-series classification via data augmentation with generative adversarial networks. *The Astrophysical Journal*, 935(1), 23.
- Gautham Adamane Pallathadka, J. A., Mojgan Aghakhanloo, Almeida, A., Amrita, S., Anders, F., Anderson, S. F., Arseneau, S., Avila, C. G., Aviram, S., Aydar, C., Badenes, C., Barrera-Baltes-teros, J. K., Bauer, F. E., Behmard, A., Berg, M., Besser, F., Bidin, C. M., Bizyaev, D., Blanc, G., Blanton, M. R., ... J. Zerniño, R. de. (2025). The Nineteenth Data Release of the Sloan Digital Sky Survey. *arXiv preprint arXiv:2507.07093*. <https://arxiv.org/abs/2507.07093>
- Grassi, T., Pineda, J., Spezzano, S., Arzoumanian, D., Lique, F., Misugi, Y., Redaelli, E., Jensen, S., & Caselli, P. (2026). A differentiable and optimizable 3D model for interpretation of observed spectral data cubes. *arXiv preprint arXiv:2603.06791*.
- Haghjoo, A., Hemmati, S., Mobasher, B., Chartab, N., Vega, A. de la, Eifler, T., Everetts, E., Nayyeri, H., & Sattari, Z. (2026). Learning to See Sharper: A Physics-Informed Artificial Intelligence Framework for Super-Resolving Galaxy Spectra. *arXiv preprint arXiv:2603.18357*.
- Hertzsprung, E. (1911). Über die Verwendung photographischer effektiver Wellenlängen zur Bestimmung von Farbenäquivalenten. *Publikationen des Astrophysikalischen Observatoriums zu Potsdam*, 22(63).
- Hu, J., Shen, L., & Sun, G. (2018). Squeeze-and-excitation networks. *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, 7132-7141. <https://doi.org/10.1109/CVPR.2018.00745>

- Huang, B., Yuan, H., Xiang, M., Huang, Y., Xiao, K., Xu, S., Zhang, R., Yang, L., Niu, Z., & Gu, H. (2024). *A comprehensive correction of the Gaia DR3 XP spectra*. <https://doi.org/10.48550/arXiv.2401.12006>
- Huber, P. J. (1964). Robust Estimation of a Location Parameter. *The Annals of Mathematical Statistics*, 35(1), 73-101. <https://doi.org/10.1214/aoms/1177703732>
- Kingma, D. P., & Ba, J. (2014). Adam: A Method for Stochastic Optimization. *arXiv preprint arXiv:1412.6980*. <https://doi.org/10.48550/arXiv.1412.6980>
- Laroche, A., & Speagle, J. S. (2025). Closing the stellar labels gap: Stellar label independent evidence for $[\alpha/M]$ information in Gaia BP/RP spectra. *The Astrophysical Journal*, 979(1), 5.
- Lee, Y. S., Beers, T. C., Sivarani, T., Allende Prieto, C., & others. (2008). The SEGUE Stellar Parameter Pipeline. I. Description and Initial Validation Tests. *The Astronomical Journal*, 136(5), 2022-2049. <https://doi.org/10.1088/0004-6256/136/5/2022>
- Recio-Blanco, A., Laverny, P. de, Allende Prieto, C., Fustes, D., Manteiga, M., Arcay, B., Bijaoui, A., Dafonte, C., Ordenovic, C., & Ordoñez Blanco, D. (2016). Stellar parametrization from Gaia RVS spectra. *Astronomy & Astrophysics*, 585, A93. <https://doi.org/10.1051/0004-6361/201425030>
- Ronneberger, O., Fischer, P., & Brox, T. (2015). U-Net: Convolutional networks for biomedical image segmentation. *Medical Image Computing and Computer-Assisted Intervention – MICCAI 2015*, 234-241. https://doi.org/10.1007/978-3-319-24574-4_28
- Russell, H. N. (1914). Relations Between the Spectra and Other Characteristics of the Stars. *Popular Astronomy*, 22, 275-294.
- Schmidt, R. M. (2019,). *Recurrent Neural Networks (RNNs): A gentle Introduction and Overview*. <https://doi.org/10.48550/arXiv.1912.05911>

- Schuster, M., & Paliwal, K. K. (1997). Bidirectional Recurrent Neural Networks. *IEEE Transactions on Signal Processing*, 45(11), 2673-2681. <https://doi.org/10.1109/78.650093>
- Sloan Digital Sky Survey Collaboration. (2025,). *Sloan Digital Sky Survey (SDSS)*. <https://www.sdss.org/>
- Ting, Y.-S. (2025). Deep learning in astrophysics. *arXiv preprint arXiv:2510.10713*.
- Vallenari, A. and, Brown, A. G. A., Prusti, T., Bruijne, J. H. J. de, Arenou, F., Babusiaux, C., Biermann, M., Creevey, O. L., Ducourant, C., & al. (2023). Gaia Data Release 3: Summary of the content and survey properties. *Astronomy & Astrophysics*, 674, A1. <https://doi.org/10.1051/0004-6361/202243940>
- Vaswani, A., Shazeer, N., Parmar, N., Uszkoreit, J., Jones, L., Gomez, A. N., Kaiser, Ł., & Polosukhin, I. (2017). Attention Is All You Need. *arXiv preprint arXiv:1706.03762*. <https://doi.org/10.48550/arXiv.1706.03762>
- Witten, C. E. C., Sharma, S., Buder, S., & Asplund, M. (2023). Information content of BP/RP spectra in Gaia DR3. *Monthly Notices of the Royal Astronomical Society*, 520(2), 2829-2842. <https://doi.org/10.1093/mnras/stad207>
- York, D. G., Adelman, J., Anderson, J. E., Jr., Anderson, S. F., Annis, J., Bahcall, N. A., Bakken, J. A., Barkhouser, R., Bastian, S., Berman, E., Boroski, W. N., Bracker, S., Briegel, C., Briggs, J. W., Brinkmann, J., Brunner, R., Burles, S., Carey, L., Carr, M. A., ... Yasuda, N. (2000). The Sloan Digital Sky Survey: Technical Summary. *The Astronomical Journal*, 120(3), 1579-1587. <https://doi.org/10.1086/301513>
- Zhang, X., Green, G. M., & Rix, H.-W. (2023). Parameters of 220 million stars from Gaia BP/RP spectra. *Monthly Notices of the Royal Astronomical Society*, 524(2), 1855-1884. <https://arxiv.org/abs/2303.03420>