



Universidad Internacional de la Rioja (UNIR)

**Escuela Superior de Ingeniería y
Tecnología**

Máster Universitario en Inteligencia Artificial

**Redes Generativas de
Aprendizaje Profundo para la
mejora de la señal astronómica**

Trabajo Fin de Estudios

presentado por: Carla Sequero, J. Javier Cacho

Dirigido por: Dr. Guillermo Torralba Elipe

Ciudad:

Fecha: 2026-02-05

Índice de Contenidos

Resumen	IV
Abstract	V
1. Índice de acrónimos	1
2. Introducción	2
2.1. Motivación	2
2.2. Planteamiento del trabajo	3
2.3. Estructura del trabajo	3
3. Contexto y estado del arte	5
3.1. Contexto del problema	5
3.1.1. Espectros estelares	5
3.1.2. Datos espectrales de Gaia	6
3.1.3. Datos espectrales de SDSS	6
3.1.4. Comparativa de los espectros de Gaia y SDSS	7
3.2. Estado del arte	8
3.2.1. Modelos generativos en Astronomía	8
3.2.2. Aprendizaje profundo en Astrofísica	9
3.3. Conclusiones	10
4. Objetivos concretos y metodología de trabajo	12
4.1. Objetivo general	12
4.2. Objetivos específicos	12
4.2.1. Análisis exploratorio de los datos	12
4.2.2. Preselección de los datos	12
4.2.3. Extracción de los datos	12
4.2.4. Preprocesado de los datos	13
4.2.5. Preparación de los conjuntos de entrenamiento, test y validación	13
4.2.6. Selección del sistema IA más adecuado	13
4.2.7. Entrenamiento, refinamiento y validación del modelo	13
4.2.8. Puesta en servicio del modelo	13
4.3. Metodología de trabajo	13
4.4. Organización del trabajo en grupo	14
5. Identificación de requisitos	15
6. Proyecto piloto	16
6.1. Creación de la base de datos	16
6.2. Entrenamiento del modelo	16
6.3. Validación del modelo	18
7. Evaluación	21
8. Conclusiones y trabajo futuro	22
8.1. Conclusiones	22
8.2. Trabajo futuro	23
Referencias bibliográficas	24

Índice de Ilustraciones

Figura 3.1	Ejemplo de espectro estelar observado por SDSS	5
Figura 3.2	Ejemplo aleatorio del espectro captado de un mismo cuerpo por Gaia y SDSS ...	7
Figura 6.1	Ejemplo 1 del espectro generado por el modelo y los de Gaia y SDSS originales .	19
Figura 6.2	Ejemplo 2 del espectro generado por el modelo y los de Gaia y SDSS originales .	19

Índice de Tablas

Resumen

En este trabajo proponemos un enfoque innovador para mejorar la calidad de las señales astronómicas captadas por los fotómetros azul y rojo (BP/RP, *Blue Photometer* y *Red Photometer*) del satélite Gaia. Al entrenar un modelo a partir de la gran cantidad de datos de baja resolución recopilados por la misión Gaia y cruzarlos con las observaciones terrestres de alta resolución, se esperan encontrar patrones ocultos que puedan aplicarse a los datos de baja resolución para aproximar los de alta resolución. Para evaluar este método se usan varios subconjuntos del conjunto de datos original y se comparan con las observaciones reales de fuentes de alta resolución terrestres.

Palabras clave: generative ai, machine learning, blue spectrum, red spectrum, gaia, astronomy

Abstract

In this work we propose an innovative approach to improve the quality of the astronomical signals captured by the blue and red photometers (BP/RP) of the Gaia satellite. By training a model from the huge amount of low resolution data collected by the Gaia mission and the cross matched best high resolution ground based observations we expect to find hidden patterns that can be applied to allow the usage of these low resolution spectrum as proxy for high resolution ones. We evaluate our method on several benchmark subsets of the original dataset by comparing it with the real observations from high resolution sources.

Keywords: generative ai, machine learning, blue spectrum, red spectrum, gaia, astronomy

1. Índice de acrónimos

Acrónimo	Significado
ADQL	<i>Astronomical Data Query Language</i>
BP/RP	<i>Blue Photometer / Red Photometer</i>
DR	<i>Data Release</i> (liberación de datos)
ELBO	<i>Evidence Lower Bound</i>
ESA	<i>European Space Agency</i> (Agencia Espacial Europea)
FITS	<i>Flexible Image Transport System</i>
GAN	<i>Generative Adversarial Network</i> (red generativa antagónica)
IA	Inteligencia Artificial
JADES	<i>JWST Advanced Deep Extragalactic Survey</i>
JWST	<i>James Webb Space Telescope</i>
MaNGA	<i>Mapping Nearby Galaxies at Apache Point Observatory</i>
RVS	<i>Radial Velocity Spectrometer</i>
SDSS	<i>Sloan Digital Sky Survey</i>
SNR	<i>Signal-to-Noise Ratio</i> (relación señal-ruido)
XP	Espectros conjuntos BP/RP de Gaia
MAE	<i>Mean Absolute Error</i>
MSE	<i>Mean Squared Error</i>

2. Introducción

En diciembre de 2013 comenzó la misión Gaia (Gaia Collaboration et al., 2023) con el objetivo de crear un mapa que permita conocer más detalles del Sistema Solar y la Vía Láctea. Esta misión es considerada la sucesora de Hipparcos dentro de ESA, siendo este el primer satélite dedicado a la astrometría. Dicha misión fue puesta en marcha en el 1989 y finalizó en el 1993. Los datos que Gaia aporta son 200 veces más precisos que los obtenidos por dicho satélite, pero aun así, de menor calidad que los obtenidos por otros proyectos actuales.

La propia agencia ESA describe en el reporte publicado en 2013 donde explicaban detalles de la misión de Gaia (Clark, 2013) que antes de estudiar un objeto celeste, es necesario poder ubicarlo en el plano, de lo contrario solo tendrían un conjunto de datos sin sentido pertenecientes a un mismo conjunto, pero sin un orden o punto de referencia, en sus propias palabras, describen lo siguiente:

«Antes de que los astrónomos puedan estudiar un objeto celeste, deben saber dónde encontrarlo. Sin este conocimiento, los astrónomos vagarían en vano en lo que Galileo alguna vez llamó un oscuro laberinto»

Por este motivo, la misión principal de Gaia se puede considerar muy útil para continuar desarrollando estudios y conocimientos acerca del universo.

Más allá de este objetivo, Gaia ha podido aportar descubrimientos de objetos celestes que anteriormente no conocíamos. Esta misión ha proporcionado uno de los catálogos más extensos y precisos hasta la fecha (Gaia Collaboration et al., 2023), no solo aportando datos astrométricos, sino que también fotométricos y espectrofotométricos.

Otras misiones, como ahora la iniciada en el año 2000 con *Sloan Digital Sky Survey* (SDSS), son capaces de proporcionar mediciones con mayor resolución que Gaia, pero con un número de objetos observados y una cobertura del cielo mucho menores (Albareti et al., 2017). De este hecho parte la idea del trabajo que se desarrolla a continuación.

Si se pudiese definir una similitud entre los espectros obtenidos por Gaia y SDSS, conseguiríamos combinar lo mejor de ambos proyectos, el rango espacial que Gaia ha sido capaz de conseguir junto a la calidad y detalle que SDSS conlleva. En este contexto, gracias a los avances constantes de la inteligencia artificial, en este trabajo proponemos explorar técnicas que nos permitan llevar a cabo este objetivo; convertir espectros de Gaia en su equivalente SDSS.

2.1. Motivación

A lo largo de 2026 se publicarán los últimos datos recolectados por Gaia en un último DR4 y catálogo final DR5. Se calcula que a lo largo de la misión, unos 2 000 millones de estrellas y otros objetos celestes fueron captados por el satélite. Gracias a los datos recolectados, se dispone de

una imagen reconstruida sobre cómo un observador vería nuestra galaxia desde el exterior de esta (Gaia Collaboration et al., 2023). Esta hazaña se ha conseguido a base de un conjunto de datos donde la información del cuerpo celeste parte fundamentalmente de dos espectros de baja resolución. La espectroscopía es una de las herramientas principales de la astrofísica para extraer información acerca de los cuerpos astronómicos. Gracias a la distribución de la luz en función de la longitud de onda, se pueden conocer detalles clave acerca de los objetos estudiados, como por ejemplo su composición, la temperatura y la gravedad superficial.

A diferencia de Gaia, otros proyectos astronómicos como SDSS presentan una resolución espectral mayor en gran parte del rango de longitudes de onda que ambos comparten (en el resto del rango, simplemente no disponen de datos). Como contrapartida, al tratarse de un sondeo terrestre que depende de dos telescopios situados en el Observatorio Apache Point de Nuevo México y en el de Las Campanas de Carnegie en Chile (Albareti et al., 2017), el número de objetos que SDSS puede observar es muy inferior al de Gaia.

La motivación de este trabajo parte de explorar si técnicas de aprendizaje automático pueden aprender a relacionar la gran cantidad de datos captados por Gaia y los espectros de mayor calidad de SDSS. Si se modela la relación entre ambos datos, se conseguiría mejorar la información obtenida a partir de los datos recolectados por Gaia.

2.2. Planteamiento del trabajo

El objetivo principal del trabajo que se desarrolla a continuación es diseñar un modelo basado en redes neuronales que consiga convertir espectros de Gaia en espectros equivalentes a los de SDSS. De esta forma conseguiríamos encontrar un modelo que relacione los datos captados por ambos proyectos.

Para llevarlo a cabo, primero debemos entender las características de ambas fuentes de información, dado que los datos que usaremos deben estar correlacionados entre ambos conjuntos de datos. En concreto nos centraremos en la tercera liberación de datos de Gaia (Gaia DR3) (Gaia Collaboration et al., 2023) y la decimotercera de SDSS (DR13) (Albareti et al., 2017), debido a que estos son los que en el DR3 de Gaia ya encontramos semi comparados, o por lo menos las asociaciones de vecindad hechas. Para ser exactos, trataremos de relacionar los espectros de baja resolución XP de Gaia DR3 (constituidos por los espectros azul y rojo) y los espectros ópticos de SDSS DR13.

Para realizar este trabajo seleccionamos el conjunto de datos de Gaia como base de estudio por diferentes motivos, por un lado, estas observaciones son parte de un estudio actual y al mismo tiempo la forma de acceder a los datos es relativamente sencilla, pero por otro, es muy destacable la gran cantidad de información y cuerpos observados que Gaia dispone. Esto nos permite tener una buena base para tratar de sacar comparaciones con otros satélites y al mismo tiempo justifica la magnitud del efecto que tendría su mejora.

2.3. Estructura del trabajo

El resto de este documento se organiza de la siguiente manera:

En el Capítulo 2 se explican los fundamentos teóricos necesarios para entender los espectros estelares y los conjuntos de datos empleados, y se revisa el estado del arte de los modelos generativos y del aprendizaje profundo aplicados a la astronomía.

En el Capítulo 3 se definen el objetivo general y los objetivos específicos del trabajo, así como la metodología seguida para alcanzarlos, aportando detalles acerca de los datos y librerías usadas.

En el Capítulo 4 se identifican los requisitos del sistema desarrollado.

En el Capítulo 5 se describe el proyecto piloto desarrollado: el trabajo realizado en cada etapa de la metodología y la herramienta *software* construida para la extracción de los datos, el entrenamiento del modelo y su puesta en servicio.

En el Capítulo 6 se evalúan los resultados obtenidos por el modelo frente a las observaciones reales de SDSS.

Finalmente, en el Capítulo 7 se recogen las conclusiones del trabajo y se proponen posibles líneas de trabajo futuro.

3. Contexto y estado del arte

En esta sección se dará un contexto al problema anteriormente descrito, comenzando desde la base del conocimiento necesario para entender los datos, hasta las técnicas que se usarán para el desarrollo del modelo de aprendizaje automático.

Por otro lado, también exploraremos trabajos ya publicados que contengan estudios de alta utilidad para el presente.

3.1. Contexto del problema

A continuación nos centraremos en desarrollar términos relativos a los espectros estelares, su interpretación y cómo se obtienen y definen en las bases de datos de cada proyecto.

3.1.1. Espectros estelares

Podemos definir un espectro estelar como la función que relaciona el flujo captado de una estrella en función de la longitud de onda. Gracias a dicha función, se obtiene la distribución de la energía que emite el cuerpo celeste según el rango óptico dado, lo que permite estudiar ciertas características del cuerpo. Por ejemplo, si nos centramos en los picos del gráfico resultante de su representación, se puede analizar la composición del cuerpo o metalicidad, dado que cada elemento emite o absorbe luz en diferentes rangos. Al mismo tiempo, de este dato también se puede estudiar la temperatura en la que se encuentra dicho elemento. Por otro lado, si nos centramos en la anchura de las líneas, hablaríamos de datos como la gravedad superficial. En la Figura 3.1 se muestra un ejemplo de espectro estelar observado por SDSS, donde se pueden apreciar las líneas de absorción y emisión mencionadas.




Figura 3.1: Ejemplo de espectro estelar observado por SDSS

Hay estudios existentes que desarrollan la conexión entre los espectros y las variables anteriormente mencionadas, por ejemplo Lee et al. (2008) trataron los datos de SDSS en su sexta

liberación de datos para tratar de crear herramientas automatizadas que estableciesen dicha relación.

Paralelamente, en la unidad de control número 8 de Gaia se trata de establecer la misma relación, como se puede observar en el trabajo llevado a cabo por Witten et al. (2023), donde llegaron a identificar de manera detallada la proporción de composición metálica de las estrellas observadas.

En los siguientes apartados comentaremos los datos espectrales de Gaia y SDSS.

3.1.2. Datos espectrales de Gaia

El satélite Gaia consta de 3 instrumentos para detectar la luz que recogen los telescopios del satélite (Gaia Collaboration et al., 2023). El primero, conocido como astrómetro, mide las posiciones estelares en el cielo, el espectrómetro medirá las velocidades radiales (RVS) y, por último, el instrumento fotométrico aportará dos espectros de baja resolución de dos bandas ópticas, la azul y la roja. Cabe destacar que, debido al movimiento rotativo de Gaia, se toman unas 70 mediciones fotométricas de cada cuerpo celeste. Estos espectros son preprocesados y tratados por diferentes unidades de coordinación antes de formar parte del conjunto de datos que nosotros usaremos en este trabajo, por lo que el ruido de fondo ya habrá sido reducido significativamente.

El satélite en cuestión se encuentra en una posición espacial conocida como L_2 , ubicada a 1,5 millones de kilómetros de la Tierra y donde las fuerzas gravitacionales del Sol, la Tierra y la Luna están en equilibrio. Por otro lado, el satélite, el Sol y la Tierra siempre van a permanecer alineados, impidiendo así que ninguno de los cuerpos celestes mencionados se interponga en el campo de visión de Gaia.

La espectrofotometría en la que nos basaremos durante el desarrollo de este trabajo es la BP/RP, también denominada espectro XP. Como hemos comentado, estos datos proceden del *Blue Photometer* y *Red Photometer*, lo que permite cubrir entre los 330 y 680 nm gracias al espectro azul y de los 640 a 1050 nm gracias al rojo (Zhang et al., 2023). Estos datos se representan por aproximadamente 110 elementos efectivos de resolución, con un poder de resolución variable según la longitud de onda de aproximadamente $R \sim 50 - 160$. Este detalle conlleva que en la tercera liberación de datos de Gaia (DR3) no obtengamos directamente una tabla de relación flujo - longitud de onda, sino que los espectros vienen dados por coeficientes que deben transformarse con ayuda de librerías como *GaiaXP* o su correspondiente desarrollo con funciones lineales (De Angeli et al., 2023).

3.1.3. Datos espectrales de SDSS

En contraposición a Gaia, este trabajo también usará y analizará datos conseguidos gracias a SDSS, proyecto iniciado con el mismo objetivo que Gaia, crear un mapa tridimensional, pero, a diferencia de este, basado en observaciones terrestres. En este caso, el mapa actual creado gracias a este sondeo contiene más de 930 000 galaxias.

La primera operación bajo el nombre SDSS comenzó en el año 2000, y sigue activo con su quinta fase SDSS-V, que tiene planteado llegar a su fin en 2027 (SDSS Collaboration et al., 2025).

Aunque la última publicación de datos de SDSS sea la número 19, tal y como hemos comentado anteriormente, dado que el análisis de cruce de datos de Gaia DR3 se ha llevado a cabo con el DR13 de SDSS, este será usado durante el estudio aunque no pertenezca a la fase más avanzada del proyecto sino a la cuarta.

A diferencia de Gaia, SDSS proporciona directamente espectros ópticos en longitud de onda y flujo, y estos datos se almacenan distribuidos a lo largo de archivos FITS. En esta base se pueden encontrar variables como la longitud de onda (almacenada como su logaritmo decimal en la variable *loglam*, de modo que $\lambda = 10^{\loglam}$) y el flujo espectral (*flux*).

Dentro del proyecto de SDSS, el programa MaNGA (*Mapping Nearby Galaxies at Apache Point Observatory*) se encarga de procesar los datos con tal de crear el mapa estelar, en su artículo original para SDSS-IV (Bundy et al., 2015) encontramos que el rango espectral aproximado de SDSS se mantiene entre los 360 y 1030 nm y su resolución se encuentra en $R \sim 2000$.

3.1.4. Comparativa de los espectros de Gaia y SDSS

Gaia y SDSS comparten gran parte de su rango óptico pero con datos captados con estrategias e instrumentos diferentes. Esto se enfatiza cuando comparamos los espectros observados por cada proyecto acerca del mismo cuerpo celeste. En la Figura 3.2 se muestra un ejemplo aleatorio.




Figura 3.2: Ejemplo aleatorio del espectro captado de un mismo cuerpo por Gaia y SDSS. Podemos observar como claramente el intervalo que SDSS cubre es muy similar a Gaia, pero existe una gran diferencia en cuanto a la suavidad de las curvas representadas. Como vemos, SDSS incluye muchos más detalles que Gaia, su espectro tiene una calidad superior. Por otro lado, si nos fijamos en los datos captados en los extremos de visión de Gaia, notamos la posibilidad de que en rangos inferiores a 400 nm estemos observando artefactos u obteniendo mediciones muy poco precisas. Lo mismo sucede en valores superiores a 950 nm.

A lo largo del trabajo, para garantizar que los datos analizados correspondan al mismo objeto astronómico, se empleará la tabla de cruce oficial de DR3 denominada *gaiadr3.sdssdr13_best_neighbour*. Esta tabla contiene para cada cuerpo observado por Gaia, el vecino más cercano en SDSS DR13, es decir, el que cuenta con una mayor probabilidad de

que estén describiendo el mismo cuerpo celeste. El procedimiento con el cual se establece esta vecindad se encuentra descrito en la documentación oficial de Gaia DR3 (Gaia Collaboration & European Space Agency, 2023), que puede consultarse en el propio archivo de Gaia. Dentro de este conjunto, definiremos un umbral de aceptación dado por la distancia angular, fijado en 2 segundos de arco.

3.2. Estado del arte

En los últimos años, la astronomía se ha beneficiado de las técnicas de aprendizaje automático, principalmente en tareas tradicionales como clasificación y agrupamiento. Por ejemplo, Djorgovski et al. (2022) señalan que «una amplia variedad de métodos de clasificación y agrupamiento se ha aplicado a estas tareas, y sigue siendo un área de investigación muy activa». En efecto, muchos esfuerzos han estado enfocados en reconocer tipos de estrellas o galaxias, identificar eventos transitorios, y diferenciar estrellas de galaxias, aprovechando catálogos masivos con miles de características. Estos enfoques basados en aprendizaje automático clásico han permitido lidiar con el flujo de datos de observaciones astronómicas mediante el uso de la clasificación supervisada o el agrupamiento no supervisado.

3.2.1. Modelos generativos en Astronomía

Paralelamente, ha crecido el interés en generar datos astronómicos sintéticos mediante modelos generativos. En particular, las redes generativas antagónicas (*Generative Adversarial Networks*, GAN) se han aplicado con éxito en algunos contextos. Por ejemplo, García-Jara et al. (2022) propusieron un método de mejora de datos (*data augmentation*) basado en GAN para generar curvas de luz sintéticas de estrellas variables y mostraron cómo su modelo logra producir variaciones realistas de luminosidad, mejorando significativamente la precisión que alcanza la clasificación cuando se entrena con estos datos sintéticos adicionales. Esto ejemplifica cómo las GAN pueden crear nuevos ejemplos de baja complejidad (en este caso series temporales) para compensar la escasez de datos etiquetados.

Asimismo, dada la enorme base de datos espectrales de baja resolución de la misión Gaia (más de 220 millones de espectros BP/RP en Gaia DR3), se han desarrollado modelos generativos específicos para estos datos. Laroche & Speagle (2025) introdujeron un *autoencoder* variacional generativo no supervisado que aprende directamente de los espectros Gaia sin necesidad de etiquetas estelares. Su arquitectura sigue el esquema *encoder-decoder* propio de los *autoencoders* variacionales: un codificador comprime los coeficientes de los espectros BP/RP en un espacio latente de baja dimensión y un decodificador reconstruye el espectro a partir de dicha representación, entrenándose ambos de forma conjunta mediante la optimización de la cota inferior de la evidencia (*evidence lower bound*, ELBO). Su modelo reproduce los espectros BP/RP y detecta patrones en áreas donde el aprendizaje supervisado falla debido a la falta de referencias. De hecho, antes de este trabajo la única aproximación generativa para los espectros de Gaia era supervisada: Zhang et al. (2023) entrenaron un modelo capaz de generar el espectro XP a partir de los parámetros estelares, apoyándose para ello en un conjunto reducido de estrellas de Gaia que cuentan con una observación equivalente en el sondeo espectroscópico terrestre LAMOST,

del cual se obtuvieron dichos parámetros de referencia. Estos desarrollos recientes demuestran que los modelos generativos pueden explorar el conjunto masivo de datos Gaia para *aproximar* datos de mayor resolución.

3.2.2. Aprendizaje profundo en Astrofísica

A pesar de estos avances, el uso de redes neuronales profundas en astronomía sigue siendo relativamente reciente y sujeto a debate. Ting (2025) destaca que, aunque estas técnicas ofrecen *perspectivas diversas* y capacidades de modelar relaciones complejas, todavía enfrentan retos importantes. Según Ting, la astronomía ha entrado en una era de datos sin precedentes, lo que ha impulsado a muchos investigadores a adoptar métodos de aprendizaje profundo para procesar observaciones modernas. Sin embargo, las reacciones varían: algunos científicos ven estas redes profundas como herramientas transformadoras, mientras que otros se muestran escépticos sobre sus verdaderas ventajas. En este contexto, se advierte que aunque las arquitecturas neuronales pueden incorporar sesgos físicos (simetrías, leyes de conservación) en su diseño para generalizar mejor, sigue siendo necesario evaluar cuidadosamente sus resultados. En resumen, el aprendizaje profundo en astrofísica está emergiendo como una vía prometedora que aún se encuentra en una fase exploratoria y que requiere una validación rigurosa antes de tener una aceptación generalizada en este dominio.

Dentro de las evoluciones recientes encontramos el trabajo Grassi et al. (2026), en el que se explora la integración de modelos físicos dentro de arquitecturas de aprendizaje automático, mediante el desarrollo de un modelo geométrico 3D completamente diferenciable para la interpretación de cubos de datos espectrales moleculares. Mediante el uso de librerías de diferenciación automática como JAX, generaron observaciones sintéticas a partir de campos de densidad y velocidad parametrizados, optimizándolos iterativamente para reproducir con precisión las observaciones astronómicas reales. Aunque este enfoque orientado a la física difiere de las redes neuronales generativas utilizadas para relacionar directamente las bandas fotométricas con espectros de alta resolución, subraya la importancia de emplear modelos computacionales avanzados y generación sintética de datos para sortear las limitaciones instrumentales y extraer propiedades subyacentes de las señales astrofísicas, especialmente para la comprensión de la composición química de los objetos celestes radiando dichas señales.

El ejemplo más cercano al enfoque propuesto en este trabajo lo encontramos en un trabajo muy reciente de Hagjoo et al. (2026). En esta propuesta, se usó el conjunto de datos de JADES (Curtis-Lake et al., 2025) que proporciona imágenes y espectroscopía profunda combinando observaciones de la cámara (NIRCam) y el espectrógrafo (NIRSpec) del JWST. Este sondeo es ideal para el estudio porque observa los mismos objetivos de galaxias utilizando una combinación de espectroscopía de prisma de baja resolución ($R \sim 30-300$) y modos de red de difracción de media resolución ($R \sim 1000$; mediante los instrumentos G140M, G235M y G395M). A partir de estas observaciones emparejadas, los investigadores seleccionaron una muestra inicial de 1 187 pares de espectros coincidentes, la cual fue ampliada posteriormente a 24 927 muestras mediante técnicas de mejora de datos (*data augmentation*) para el entrenamiento del modelo.

Para llevar a cabo este estudio, los investigadores desarrollaron una red neuronal profunda personalizada de tres etapas, diseñada específicamente para procesar datos unidimensionales.

La primera etapa emplea una red neuronal convolucional residual (1D ResNet-CNN) que genera una reconstrucción preliminar y conservadora del espectro. La segunda etapa utiliza otra red convolucional para inferir el corrimiento al rojo (*redshift*), contextualizando así la posición física de los elementos. Finalmente, la tercera etapa de refinamiento divide el trabajo en dos ramas: un modelo basado en mecanismos de atención (*Transformer encoder*) que procesa de manera aislada las líneas de emisión, y otra red convolucional que ajusta suavemente el continuo del espectro. En total, esta arquitectura por fases cuenta con unos 2,5 millones de parámetros y está diseñada para aplicar correcciones basadas en la física, evitando que la IA «alucine» datos inexistentes.

Los resultados demostraron que este modelo es capaz de recuperar con éxito detalles de alta resolución a partir de observaciones de baja calidad. El sistema logró desmezclar y separar de manera efectiva líneas de emisión que aparecían fusionadas en los datos originales (como el doblete de [O III] y H β), mejorando sistemáticamente la relación señal-ruido en todas las líneas de diagnóstico clave. Además, los espectros superresueltos generados por la IA alcanzaron niveles de ruido comparables a las observaciones reales de alta resolución y permitieron realizar estimaciones del corrimiento al rojo mucho más precisas, reduciendo a la mitad la dispersión de errores y disminuyendo significativamente los casos atípicos frente a los datos de entrada.

3.3. Conclusiones

La integración y estandarización de catálogos astronómicos masivos representa un desafío técnico fundamental, especialmente al trabajar con fuentes de naturalezas distintas como Gaia y SDSS. Mientras que Gaia provee un volumen de datos astrométricos, fotométricos y espectroscópicos sin precedentes, sus espectros BP/RP operan en resoluciones bajas y requieren complejos procesos de calibración para mitigar el ruido espacial y las fluctuaciones. Cabe matizar que el espectrómetro RVS de Gaia alcanza una resolución incluso mayor que la de SDSS, pero al requerir estrellas más brillantes dispone de muchas menos fuentes observadas. En contraste, SDSS aporta espectros ópticos de mayor resolución que los BP/RP. La necesidad de interconectar ambas misiones define el núcleo de este estudio: establecer una relación sólida capaz de traducir y equiparar los espectros de baja resolución de Gaia con los espectros de mayor resolución de SDSS.

Para abordar este asunto, el análisis del estado del arte evidencia una transición desde el uso de estas herramientas únicamente para clasificación o agrupamiento clásico hacia el uso de las GAN y los *autoencoders* variacionales, que recientemente han demostrado su utilidad para la generación de datos sintéticos realistas y se establecen ya como herramientas útiles para la calibración y otras áreas relevantes en el estudio astronómico.

Avanzando aún más allá, el éxito reciente en la mejora de resolución de datos del telescopio JWST mediante modelos generativos muestra que la aplicación de estas técnicas representa una solución viable que puede ser también aplicada en el contexto del catálogo astronómico que ofrece Gaia.

El propósito de la propuesta planteada en este documento es profundizar en la aplicación de estas técnicas novedosas ofreciendo soluciones útiles que aporten mejoras tangibles en el

ámbito de la astronomía, específicamente para la mejora de las señales contenidas en el amplio catálogo que Gaia nos ofrece.

4. Objetivos concretos y metodología de trabajo

En este capítulo se detalla el objetivo principal de este trabajo y su desglose en objetivos más específicos para alcanzarlo.

También se expone la metodología empleada para afrontar dichos objetivos.

4.1. Objetivo general

El objetivo general de este trabajo consiste en desarrollar un modelo basado en aprendizaje automático que permita aproximar el flujo calibrado captado por los fotómetros de baja resolución BP/RP de Gaia a un espectro de resolución más alta, similar al proporcionado por las observaciones de mayor calidad de SDSS.

4.2. Objetivos específicos

Para alcanzar el objetivo propuesto, se deben alcanzar previamente los siguientes objetivos intermedios.

4.2.1. Análisis exploratorio de los datos

El análisis y comprensión de las observaciones y la manera en la que están organizadas en los repositorios de Gaia y SDSS es fundamental para entender cuales son los datos relevantes a extraer.

Es también necesario comprender la relación entre las mediciones de ambos sondeos astronómicos para usar observaciones coincidentes, referidas a los mismos objetos del catálogo de objetos celestes.

4.2.2. Preselección de los datos

Una vez se ha ganado cierta comprensión de los datos, se puede hacer una valoración más precisa de cuál es la calidad de los mismos, y qué valores no reúnen los requisitos para incluirse en el conjunto de datos de entrenamiento.

Así, se deben definir unos parámetros para excluir los datos menos relevantes para el objetivo principal.

4.2.3. Extracción de los datos

Tras haber comprendido qué servicios se pueden usar para la extracción de los datos y haber reducido el conjunto de entrada atendiendo a su calidad, el siguiente paso consiste en la extracción de los mismos, usando métodos que optimicen la descarga de los datos orientados a

minimizar el tiempo y los posibles errores que los servicios ofrecidos por los proyectos de Gaia y SDSS ofrecen.

4.2.4. Preprocesado de los datos

Una vez extraídos los datos, es necesario realizar cierto preprocesado de los mismos para mejorar el entrenamiento.

Puesto que en la preselección de las observaciones se han tenido en cuenta criterios de calidad, y Gaia DR3 ofrece datos ya procesados y relaciones con SDSS, el preprocesado en este caso consiste en la reducción del ruido, mejorando así la relación señal-ruido (*Signal-to-Noise Ratio*, SNR), aplicada a las observaciones de SDSS, que tienen más variabilidad y pueden así aumentar la complejidad del entrenamiento.

4.2.5. Preparación de los conjuntos de entrenamiento, test y validación

Una vez los datos están listos, es necesario realizar el reparto entre los distintos conjuntos de datos.

4.2.6. Selección del sistema IA más adecuado

Para el caso expuesto se considera que las redes neuronales pueden aportar una solución novedosa gracias a su no-linealidad.

4.2.7. Entrenamiento, refinamiento y validación del modelo

La red neuronal entrenada requerirá de un proceso de optimización y ajuste de los hiperparámetros para dar una solución satisfactoria.

4.2.8. Puesta en servicio del modelo

Una vez ajustado el modelo, el objetivo será proporcionar una manera sencilla e intuitiva de acceder a él.

4.3. Metodología de trabajo

De acuerdo a los objetivos expuestos, la metodología empleada para desarrollar este trabajo se estructura en las siguientes etapas. Las particularidades y la implementación concreta de cada una de ellas se recogen en el Capítulo 5.

1. Análisis exploratorio de los datos: mediante cuadernos *Jupyter* colaborativos se estudia la organización de los repositorios de Gaia y SDSS, los servicios disponibles para su consulta y la manera de emparejar las observaciones de ambos proyectos referidas a un mismo objeto celeste.
2. Preselección de los datos: a partir del análisis previo se definen filtros de calidad sobre el cruce de catálogos, con el objetivo de maximizar la fiabilidad de los pares de espectros utilizados.
3. Extracción de los datos: descarga por lotes de los espectros emparejados, de manera reproducible y tolerante a las limitaciones de los servicios públicos de consulta.

4. Preprocesado de los datos: limpieza de anomalías y artefactos, y homogeneización de los espectros de ambas fuentes para que sean directamente comparables. En esta etapa resulta fundamental comparar la relación señal-ruido (SNR) de los espectros: cada observatorio puede medir el mismo objeto un número distinto de veces y en condiciones diferentes, por lo que la SNR puede variar entre observaciones de un mismo cuerpo. Por ello, los pares de espectros que se usen para entrenar y evaluar el modelo deben presentar una SNR equivalente.
5. Preparación de los conjuntos de entrenamiento, validación y test: partición del conjunto de datos garantizando una distribución homogénea de las muestras, también en términos de SNR, y de manera reproducible.
6. Entrenamiento, refinamiento y validación del modelo: proceso iterativo de optimización y ajuste de hiperparámetros, evaluando el modelo sobre el conjunto de validación y reservando el conjunto de test para la evaluación final.

4.4. Organización del trabajo en grupo

Este trabajo ha sido desarrollado de manera conjunta por los dos autores. Para coordinar el desarrollo se han mantenido reuniones periódicas de seguimiento, junto con las revisiones con el director del trabajo, y se ha empleado un repositorio de control de versiones compartido tanto para el código como para la memoria, donde los avances de cada autor se han integrado mediante revisiones cruzadas.

5. Identificación de requisitos

6. Proyecto piloto

En este capítulo se describe el trabajo realizado en cada una de las etapas definidas en la metodología, junto con la herramienta *software* desarrollada.

6.1. Creación de la base de datos

Para obtener la base de datos de entrenamiento del modelo, en primer lugar, se realizó una consulta ADQL sobre la tabla *gaiadr3.gai_source*, en concreto teniendo en cuenta *gaiadr3.sdssdr13_best_neighbour*. De aquí sacamos una base de datos con aquellas observaciones que tienen la variable *XP_continuous* y cuya distancia angular respecto al cruce con SDSS es menor que 2 segundos de arco. Cabe destacar que el procedimiento explicado se llevó a cabo por lotes, dado que la base de datos de SDSS está limitada y no permite una petición de datos masiva. Para controlar que los lotes no tomaran los mismos datos de referencia, se usó la variable *gaia.random_index*. Esta es una columna de la base de datos de Gaia que permite hacer selecciones aleatorias de forma reproducible, por lo que fue usada con diferentes intervalos en cada lote procesado.

A partir de la lista de objetos obtenida, filtramos por aquellos en los que las tres variables necesarias para encontrar el espectro se encontraban disponibles. Para ser concretos, era indispensable que el objeto estudiado tuviese las variables *plate*, *mjd* y *fiberID* no nulas, dado que estas son las que se usarán para identificar la muestra del fichero FITS. Con esta información y la función *get_spectra* de la librería *astroquery*, pudimos obtener los espectros observados por SDSS de los cuerpos a estudiar.

Una vez ya estaba definida la lista de cuerpos de los que sí se dispone información en ambos proyectos, recabamos la información de Gaia. Para conseguir los coeficientes anteriormente mencionados, accedimos a *gaiadr3.xp_continuous_mean_spectrum* y guardamos las variables *bp_coefficients* y *rp_coefficients* de los objetos listados.

Este proceso de extracción ha permitido reunir hasta el momento un conjunto de datos real con más de 50 000 pares de espectros emparejados de Gaia y SDSS.

6.2. Entrenamiento del modelo

Una vez se dispone de la base de datos con los pares de espectros de Gaia y SDSS, se procedió con el preprocesamiento de los datos, diseño y entrenamiento del modelo de redes neuronales. El objetivo era conseguir un modelo que aprendiese una transformación entre los datos de entrada de Gaia y el espectro de SDSS asociado. Así pues, el modelo planteado recibe como entrada un vector con el flujo de Gaia y recibe un vector con el flujo correspondiente al espectro de SDSS.

En primer lugar, cabe destacar que restringimos el intervalo de entrenamiento entre los 500 y 900 nm dado que es el rango común entre los dos satélites en el que no se observan alteraciones

debido a posibles artefactos y se evitan zonas en las que la generación de los datos de salida se vería afectada por la falta de solapamiento entre ambas observaciones.

Además, se eliminaron aquellos pares de espectros en los que encontrábamos valores no definidos o los cuales constaban de comportamientos anómalos, como por ejemplo escalas de flujo cercanas a cero, espectros constantes o rangos dinámicos extremos. Para conseguirlo, se usaron medidas basadas en percentiles de flujo, teniendo en cuenta medidas acerca del 95 o 99. Este filtrado consiguió eliminar efectos adversos en el modelo causados por datos no representativos de la muestra extraída.

También tuvimos en cuenta la relación de escala entre los espectros de Gaia y SDSS. En algunos casos observábamos que los pares diferían exageradamente sobre la escala usada, por lo que usando el mismo criterio de los percentiles nombrado anteriormente, los casos más extremos fueron eliminados. De esta forma mantuvimos los pares en los que la relación entre la entrada y la salida fuese coherente.

Finalmente, tuvimos que reducir la dimensionalidad del espectro de SDSS mediante una agrupación de bins consecutivos. SDSS contaba inicialmente con 3600 observaciones por espectro, mientras que Gaia tan solo 343. Esta diferencia suponía una dificultad añadida para el modelo, así que para abordar el problema aplicamos una función de agrupación, la cual sustituía por un único valor promedio cada bloque de n valores consecutivos del flujo de SDSS. Tras valorar los beneficios y desventajas de esta agrupación, se consideró una agrupación en conjuntos de 7 bins, reduciendo la dimensión de SDSS a 380 puntos. Este valor suponía el equilibrio entre la pérdida de información debido a la reducción de puntos y la mejora del problema de regresión del modelo.

De cara a la preparación de la base para el entrenamiento del modelo, definimos 3 subconjuntos: entrenamiento, test y validación. Los datos de test se formaron con un 20% del conjunto global y fueron usados para evaluar el modelo, por lo que no fue usado durante su entrenamiento. El 80% restante se separó de forma aleatoria entre las parejas que forman la base de entrenamiento del modelo y de validación.

Una vez definida la partición de los datos, aplicamos una normalización a través de la media y desviación típica de los datos del conjunto de entrenamiento. Gracias a este paso, se facilitó el entrenamiento de la red neuronal, ya que las variables de entrada y salida se situaban en escalas comparables.

Después de un procedimiento de prueba y error, el modelo final corresponde a una red neuronal densa, formada por una capa de entrada del tamaño de los datos de Gaia, varias capas intermedias (una con 512 neuronas y tres más con 1024) y finalmente una capa de salida con tantos puntos como el espectro de SDSS a predecir. Además, probamos diferentes funciones de activación, siendo ELU y LeakyReLU las que obtuvieron mejores resultados debido a que no anulan completamente las neuronas con valores negativos. En el problema de regresión al que nos enfrentamos, las desviaciones pueden ser positivas y negativas respecto a la media, así que el uso de los métodos mencionados anteriormente favorecía el aprendizaje.

La función de pérdida definida fue Huber, que combina el error cuadrático medio para errores pequeños, y el error absoluto medio para errores más grandes. Esto permite rebajar la penalización en aquellos casos en los que los espectros tengan desviaciones anómalas que no

deban definir el comportamiento del modelo. Se definió el optimizador Adam con una tasa de aprendizaje de 0.0001 y un recorte de gradiente con clipnorm = 1.0 para evitar las actualizaciones excesivas.

El entrenamiento se realizó con lotes de 64 muestras y un máximo de 50 épocas. Para evitar un sobreentrenamiento del modelo, definimos una función de EarlyStopping que monitorea la pérdida del set de validación y detiene el entrenamiento si después de 5 épocas no ha mejorado como mínimo un 0.0001. De la misma forma, añadimos una función de ReduceLROnPlateau que reducía la tasa de aprendizaje cuando la variable controlada se estabilizaba.

6.3. Validación del modelo

Durante el entrenamiento del modelo se pudo observar una evolución estable de las métricas controladas, tanto en el conjunto de entrenamiento como el de validación. En la última época llevada a cabo, se obtuvo una pérdida de entrenamiento de 0.0073, un error absoluto medio de 0.0670 y un error cuadrático medio de 0.0153. En el conjunto de validación las métricas obtenidas fueron muy cercanas, siendo un 0.0074 de pérdida, un MAE de 0.0676 y MSE de 0.0152. Esta similitud indica que el modelo no presenta un sobreajuste destacable, lo que conlleva que el modelo puede generalizarse de forma adecuada a datos no vistos durante su entrenamiento.

Una vez finalizado el entrenamiento del modelo, se evaluó su eficacia sobre el conjunto de test, formado por unos 5500 pares de datos. Los valores obtenidos en este conjunto tuvieron una pérdida de 0.0081, MAE de 0.0697 y MSE de 0.0168. Estos datos son cercanos a los obtenidos en la muestra de validación, reforzando la idea de que el modelo tiene un comportamiento estable ante los datos que no han sido vistos anteriormente.

Cabe destacar que las métricas calculadas anteriormente se definen sobre espectros normalizados, por lo que no mantienen la escala de las unidades de flujo entrenadas. Sin embargo, su uso ha sido necesario para poder valorar de forma comprensible la eficacia de los diferentes modelos estudiados.

Para complementar toda la explicación dada, podemos observar las gráficas detalladas en la Figura 6.1 y la Figura 6.2.




Figura 6.1: Ejemplo 1 del espectro generado por el modelo y los de Gaia y SDSS originales




Figura 6.2: Ejemplo 2 del espectro generado por el modelo y los de Gaia y SDSS originales
En ellas observamos tres espectros. Por un lado, en azul encontramos el espectro que el modelo pretende predecir, los puntos de SDSS una vez han sido recortados y agrupados. Por otro, en verde podemos ver la entrada que recibe el modelo, siendo esta el espectro calibrado de Gaia. Los puntos de Gaia han sido escalados a la misma unidad que SDSS utiliza para poder representar ambos espectros en la misma escala, pero en el entrenamiento se usan escalas diferentes, las originales de cada conjunto de datos. Finalmente, en naranja encontramos el espectro predicho por el modelo.

En gran parte de los gráficos observados, el modelo reproduce la morfología general del espectro, incluso modela gran parte de los picos más acentuados. Si bien es cierto, hay puntos

que el modelo no puede inferir debido a las estructuras detalladas de SDSS y la baja resolución inicial de Gaia.

7. Evaluación

8. Conclusiones y trabajo futuro

En este capítulo se incluyen las conclusiones obtenidas tras el desarrollo del trabajo y comentarios acerca de posibles trabajos futuros partiendo de los resultados obtenidos.

8.1. Conclusiones

A lo largo del trabajo hemos llevado a cabo todo el desarrollo necesario para poder entrenar un modelo de redes neuronales, partiendo desde la creación de la base de datos de espectros de Gaia y SDSS hasta su uso para la validación del modelo generado.

En primer lugar, la creación de la base de datos resultó no ser algo trivial. Diseñamos un proceso por etapas que nos permitió obtener a partir de espectros y datos de SDSS las observaciones de Gaia que esta categorizaba como su vecino más cercano. Se observaron diversas limitaciones en este proceso, debido a la estructura y capacidad de los servicios de consulta que disponen ambos satélites. Por este motivo, una parte importante del trabajo se basó en conseguir un método robusto y reproducible que nos permitiese crear la base de datos necesaria. Al mismo tiempo, la calidad de los pares de espectros también influyó en el estudio, se tuvieron que descartar algunos datos debido a escalas incompatibles, artefactos o espectros con un claro error en la captación de datos, como por ejemplo con valores constantes o nulos a lo largo de la longitud de onda observada.

En cuanto al modelo neuronal, planteamos un problema de regresión multivariante, cuya red recibe como entrada un espectro de Gaia y tiene el objetivo de predecir como salida un espectro de SDSS. Cabe destacar que la gran diferencia de resolución entre Gaia y SDSS implica que el modelo no sea capaz de aprender información espectral muy detallada de SDSS, es decir, no puede reconstruir de forma eficaz las estructuras finas que SDSS produce. Por este motivo, la dimensión de salida de SDSS se redujo mediante una agrupación de bins, permitiéndonos mejorar la calidad de los resultados sin perder la información básica del espectro de SDSS.

Se evaluaron diferentes arquitecturas de modelo y preprocesamientos de la base de datos, considerando definitivas las versiones que se pueden encontrar detalladas en este trabajo. De dicho proceso de prueba y error, obtuvimos resultados que demuestran que el modelo es capaz de predecir la forma general de los espectros de SDSS en gran parte de los casos. Asimismo, la comparación de las métricas de entrenamiento, validación y test permiten asegurar que el modelo no se ha sobreajustado a los datos observados durante el entrenamiento, sino que presenta capacidad para generalizar su uso sobre datos no observados.

En resumen, podemos concluir que este trabajo demuestra que es posible diseñar un modelo de redes neuronales que permita aproximar espectros captados por Gaia a una reconstrucción con menor grado de detalle de los observados por SDSS. Este hecho permite dejar una puerta abierta a varias líneas de mejora, las cuales serán comentadas en el siguiente apartado.

8.2. Trabajo futuro

Referencias bibliográficas

- Albareti, F. D., Allende Prieto, C., Almeida, A., Anders, F., Anderson, S., Andrews, B. H., & others. (2017). The Thirteenth Data Release of the Sloan Digital Sky Survey: First Spectroscopic Data from the SDSS-IV Survey Mapping Nearby Galaxies at Apache Point Observatory. *The Astrophysical Journal Supplement Series*, 233(2), 25. <https://doi.org/10.3847/1538-4365/aa8992>
- Bick, A., Blandin, A., & Deming, D. J. (2026). The rapid adoption of generative AI. *Management Science*.
- Bundy, K., Bershad, M. A., Law, D. R., Yan, R., Drory, N., MacDonald, N., Wake, D. A., Cherinka, B., Sánchez-Gallego, J. R., Weijmans, A.-M., Thomas, D., Tremonti, C., Masters, K., Coccato, L., Diamond-Stanic, A. M., Aragón-Salamanca, A., Avila-Reese, V., Badenes, C., Falcón-Barroso, J., & al. (2015). Overview of the SDSS-IV MaNGA Survey: Mapping Nearby Galaxies at Apache Point Observatory. *The Astrophysical Journal*, 798(1), 7. <https://arxiv.org/abs/1412.1482>
- Clark, S. (2013). *Gaia: El censo galáctico de la ESA. BR-296*. https://esamultimedia.esa.int/docs/science/BR-296-Spanish_Gaia_05_WEB.pdf
- Curtis-Lake, E., Cameron, A. J., Bunker, A. J., Scholtz, J., Carniani, S., Parlanti, E., D'Eugenio, F., Jakobsen, P., Willmer, C. N., Arribas, S., & others. (2025). JADES Data Release 4 Paper I: Sample Selection, Observing Strategy and Redshifts of the complete spectroscopic sample. *arXiv preprint arXiv:2510.01033*.
- De Angeli, F., Weiler, M., Montegriffo, P., Evans, D. W., Riello, M., Andrae, R., & others. (2023). Gaia Data Release 3: Processing and validation of BP/RP low-resolution spectral data. *Astronomy & Astrophysics*, 674, A2. <https://doi.org/10.1051/0004-6361/202243680>
- Djorgovski, S. G., Mahabal, A., Graham, M. J., Polsterer, K., & Krone-Martins, A. (2022). Applications of AI in Astronomy. *arXiv preprint arXiv:2212.01493*.
- Gaia Collaboration, & European Space Agency. (2023). *Gaia Data Release 3 Documentation* [Technical report]. <https://gea.esac.esa.int/archive/documentation/GDR3/>
- Gaia Collaboration, Brown, A. G. A., Vallenari, A., Prusti, T., Bruijne, J. H. J. de, & others. (2021). Gaia Early Data Release 3: Summary of the contents and survey properties. *Astronomy & Astrophysics*, 649, A1. <https://doi.org/10.1051/0004-6361/202039657>
- Gaia Collaboration, Vallenari, A., Brown, A. G. A., Prusti, T., Bruijne, J. H. J. de, Arenou, F., Babusiaux, C., Biermann, M., Creevey, O. L., Ducourant, C., & al. (2023). Gaia Data Release 3: Summary of the content and survey properties. *Astronomy & Astrophysics*, 674, A1. <https://doi.org/10.1051/0004-6361/202243940>
- García-Jara, G., Protopapas, P., & Estévez, P. A. (2022). Improving astronomical time-series classification via data augmentation with generative adversarial networks. *The Astrophysical Journal*, 935(1), 23.

- Grassi, T., Pineda, J., Spezzano, S., Arzoumanian, D., Lique, F., Misugi, Y., Redaelli, E., Jensen, S., & Caselli, P. (2026). A differentiable and optimizable 3D model for interpretation of observed spectral data cubes. *arXiv preprint arXiv:2603.06791*.
- Haghjoo, A., Hemmati, S., Mobasher, B., Chartab, N., Vega, A. de la, Eifler, T., Everetts, E., Nayyeri, H., & Sattari, Z. (2026). Learning to See Sharper: A Physics-Informed Artificial Intelligence Framework for Super-Resolving Galaxy Spectra. *arXiv preprint arXiv:2603.18357*.
- Laroche, A., & Speagle, J. S. (2025). Closing the stellar labels gap: Stellar label independent evidence for $[\alpha/M]$ information in Gaia BP/RP spectra. *The Astrophysical Journal*, 979(1), 5.
- Lee, Y. S., Beers, T. C., Sivarani, T., Allende Prieto, C., & others. (2008). The SEGUE Stellar Parameter Pipeline. I. Description and Initial Validation Tests. *The Astronomical Journal*, 136(5), 2022-2049. <https://doi.org/10.1088/0004-6256/136/5/2022>
- SDSS Collaboration, Pallathadka, G. A., Aghakhanloo, M., Aird, J., Almeida, A., Amrita, S., Anders, F., Anderson, S. F., Arseneau, S., Avila, C. G., Aviram, S., Aydar, C., Badenes, C., Barrera-Ballesteros, J. K., Bauer, F. E., Behmard, A., Berg, M., Besser, F., Bidin, C. M., ... J. Zerniño, R. de. (2025). The Nineteenth Data Release of the Sloan Digital Sky Survey. *arXiv preprint arXiv:2507.07093*. <https://arxiv.org/abs/2507.07093>
- Sloan Digital Sky Survey Collaboration. (2025,). *Sloan Digital Sky Survey (SDSS)*. <https://www.sdss.org/>
- Ting, Y.-S. (2025). Deep learning in astrophysics. *arXiv preprint arXiv:2510.10713*.
- Witten, C. E. C., Sharma, S., Buder, S., & Asplund, M. (2023). Information content of BP/RP spectra in Gaia DR3. *Monthly Notices of the Royal Astronomical Society*, 520(2), 2829-2842. <https://doi.org/10.1093/mnras/stad207>
- Zhang, X., Green, G. M., & Rix, H.-W. (2023). Parameters of 220 million stars from Gaia BP/RP spectra. *Monthly Notices of the Royal Astronomical Society*, 524(2), 1855-1884. <https://arxiv.org/abs/2303.03420>